

**Ανάλυση Δεδομένων επί Συστήματος Κοινόχρηστων Ποδηλάτων:
Μετατροπή Περιστασιακών Χρηστών σε Ετήσιους Συνδρομητές**



Νικόλαος Μπελιμπασάκης
Μηχανικός Η/Υ και Πληροφορικής

Πίνακας Περιεχομένων

1. Εισαγωγή και Παρουσίαση του Έργου	2
2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος	4
3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων	5
4. Process Phase – Καθαρισμός και Επεξεργασία Δεδομένων	7
5. Analyze Phase – Ανάλυση Δεδομένων και Εξαγωγή Επιχειρηματικών Συμπερασμάτων	15
6. Share Phase – Οπτικοποίηση Δεδομένων και Παρουσίαση Ευρημάτων	23
7. Act Phase – Τελικά Συμπεράσματα και Επιχειρηματικές Προτάσεις	24
8. Σύνοψη Έργου	26
9. Βιβλιογραφία / Αναφορές	27

1. Εισαγωγή και Παρουσίαση του Έργου

Η Cyclistic αποτελεί μία υποθετική εταιρεία παροχής υπηρεσιών κοινόχρηστων ποδηλάτων με έδρα το Σικάγο των Ηνωμένων Πολιτειών, όπως περιγράφεται στη μελέτη περίπτωσης (case study) του Google Data Analytics Professional Certificate. Η εταιρεία διαθέτει περισσότερα από 5.800 ποδήλατα και περισσότερους από 600 σταθμούς στάθμευσης, επιτρέποντας στους χρήστες να παραλαμβάνουν και να επιστρέφουν ποδήλατα σε διαφορετικά σημεία της πόλης. Επιπλέον, η Cyclistic προσφέρει διαφορετικούς τύπους ποδηλάτων, όπως κλασικά ποδήλατα, ανακλινόμενα ποδήλατα, χειροκίνητα τρίκυκλα και ποδήλατα μεταφοράς φορτίου, με στόχο την ενίσχυση της προσβασιμότητας και την εξυπηρέτηση διαφορετικών κατηγοριών χρηστών.

Η πλειονότητα των χρηστών επιλέγει τα παραδοσιακά ποδήλατα, ενώ ένα μικρό ποσοστό χρησιμοποιεί τις ειδικές υποστηρικτικές επιλογές. Παράλληλα, σημαντικό μέρος των χρηστών χρησιμοποιεί τις υπηρεσίες της εταιρείας είτε για ψυχαγωγικούς σκοπούς είτε για καθημερινή μετακίνηση προς την εργασία. Η εταιρεία βασίζεται σε ένα ευέλικτο σύστημα συνδρομών, το οποίο περιλαμβάνει μεμονωμένες διαδρομές, ημερήσια πάσα και ετήσιες συνδρομές. Οι χρήστες που χρησιμοποιούν μεμονωμένες ή ημερήσιες διαδρομές χαρακτηρίζονται ως περιστασιακοί χρήστες (casual riders), ενώ οι χρήστες που διαθέτουν ετήσια συνδρομή χαρακτηρίζονται ως μέλη (annual members).

Σύμφωνα με τα επιχειρηματικά δεδομένα της υποθετικής εταιρείας, οι ετήσιοι συνδρομητές αποφέρουν σημαντικά μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες. Για τον λόγο αυτό, η Cyclistic επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, αναπτύσσοντας νέες στρατηγικές marketing που θα στοχεύουν στη μετατροπή περιστασιακών χρηστών σε μόνιμα μέλη της υπηρεσίας.

Σημαντικό ρόλο στη διαδικασία αυτή διαδραματίζει η Lily Moreno, η οποία αποτελεί τη διευθύντρια marketing της Cyclistic και υπεύθυνη για την ανάπτυξη διαφημιστικών καμπανιών και στρατηγικών προώθησης της υπηρεσίας. Η Moreno πιστεύει ότι η μελλοντική ανάπτυξη της εταιρείας εξαρτάται από τη μεγιστοποίηση των ετήσιων συνδρομών και θεωρεί ότι οι υπάρχοντες περιστασιακοί χρήστες αποτελούν την καλύτερη ευκαιρία για μελλοντική ανάπτυξη, καθώς είναι ήδη εξοικειωμένοι με τις υπηρεσίες της Cyclistic.

Παράλληλα, η ομάδα marketing analytics της εταιρείας είναι υπεύθυνη για τη συλλογή, ανάλυση και παρουσίαση δεδομένων που συμβάλλουν στη λήψη επιχειρηματικών αποφάσεων και στη διαμόρφωση στρατηγικών marketing. Στο πλαίσιο της μελέτης περίπτωσης, ο ρόλος του αναλυτή δεδομένων είναι η

επεξεργασία και ανάλυση των ιστορικών δεδομένων διαδρομών, με σκοπό την εξαγωγή χρήσιμων συμπερασμάτων σχετικά με τις διαφορές στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Επιπλέον, η διοικητική ομάδα της Cyclistic είναι υπεύθυνη για την αξιολόγηση των αποτελεσμάτων της ανάλυσης και την έγκριση των προτεινόμενων στρατηγικών marketing.

Το παρόν έργο αποτελεί μία ολοκληρωμένη μελέτη ανάλυσης δεδομένων, η οποία υλοποιείται στα πλαίσια του Google Data Analytics Professional Certificate [\[1\]](#). Κύριος στόχος του έργου είναι η ανάλυση ιστορικών δεδομένων διαδρομών της Cyclistic, με σκοπό την κατανόηση των διαφορών στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Μέσα από τις διαδικασίες συλλογής, καθαρισμού, επεξεργασίας, ανάλυσης και οπτικοποίησης δεδομένων, επιδιώκεται η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που μπορούν να συμβάλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος

Η φάση “Ask” αποτελεί το πρώτο στάδιο της διαδικασίας ανάλυσης δεδομένων και επικεντρώνεται στον καθορισμό του επιχειρηματικού προβλήματος, των βασικών στόχων της ανάλυσης και των ερευνητικών ερωτημάτων που θα καθοδηγήσουν τη μελέτη. Στην παρούσα μελέτη περίπτωσης, η Cyclistic επιδιώκει να κατανοήσει καλύτερα τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων, με στόχο την ανάπτυξη αποτελεσματικότερων στρατηγικών marketing.

Σύμφωνα με τα επιχειρηματικά δεδομένα της εταιρείας, οι ετήσιοι συνδρομητές (annual members) αποφέρουν μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες (casual riders). Για τον λόγο αυτό, η εταιρεία επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, μετατρέποντας όσο το δυνατόν περισσότερους περιστασιακούς χρήστες σε μόνιμα μέλη της υπηρεσίας.

Για την επίτευξη του παραπάνω στόχου, η ομάδα marketing της Cyclistic διατύπωσε τρία βασικά ερευνητικά ερωτήματα, τα οποία θα καθοδηγήσουν τη μελλοντική στρατηγική marketing της εταιρείας:

1. Πώς χρησιμοποιούν διαφορετικά τα ποδήλατα της Cyclistic οι ετήσιοι συνδρομητές και οι περιστασιακοί χρήστες;
2. Γιατί οι περιστασιακοί χρήστες θα επέλεγαν μία ετήσια συνδρομή;
3. Πώς μπορεί η Cyclistic να αξιοποιήσει τα ψηφιακά μέσα (digital media) ώστε να επηρεάσει τους περιστασιακούς χρήστες και να τους μετατρέψει σε ετήσιους συνδρομητές;

Στα πλαίσια της παρούσας μελέτης, η ανάλυση επικεντρώνεται κυρίως στο πρώτο ερευνητικό ερώτημα, δηλαδή στην κατανόηση των διαφορών στη συμπεριφορά μεταξύ ετήσιων συνδρομητών και περιστασιακών χρηστών. Μέσα από την ανάλυση ιστορικών δεδομένων διαδρομών, επιδιώκεται η αναγνώριση προτύπων χρήσης, τάσεων και διαφορών στις συνήθειες των δύο κατηγοριών χρηστών.

Οι βασικοί stakeholders της μελέτης είναι η Lily Moreno, διευθύντρια marketing της Cyclistic, η ομάδα marketing analytics της εταιρείας, καθώς και η διοικητική ομάδα της Cyclistic, η οποία θα αξιολογήσει τα αποτελέσματα της ανάλυσης και τις προτεινόμενες στρατηγικές marketing.

Τέλος, βασικός στόχος της ανάλυσης είναι η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που θα μπορούσαν να συμβάλλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων

Η φάση “Prepare” επικεντρώνεται στη συλλογή, οργάνωση και προετοιμασία των δεδομένων που θα χρησιμοποιηθούν για την ανάλυση. Στην παρούσα μελέτη χρησιμοποιήθηκαν τα ιστορικά δεδομένα διαδρομών της Cyclistic [2], τα οποία παρέχονται στα πλαίσια του case study του Google Data Analytics Professional Certificate. Τα δεδομένα αυτά είναι δημόσια διαθέσιμα και περιλαμβάνουν πληροφορίες σχετικά με τις διαδρομές των χρηστών του συστήματος κοινόχρηστων ποδηλάτων.

Τα datasets περιέχουν πληροφορίες όπως το μοναδικό αναγνωριστικό κάθε διαδρομής (trip_id), τον χρόνο έναρξης και λήξης της διαδρομής, τη διάρκεια της διαδρομής, τους σταθμούς εκκίνησης και τερματισμού, τον τύπο χρήστη (casual rider ή annual member), καθώς και πρόσθετα στοιχεία σχετικά με τα ποδήλατα και τις διαδρομές. Τα δεδομένα οργανώνονται σε μορφή πινάκων CSV, γεγονός που επιτρέπει την εύκολη επεξεργασία και ανάλυσή τους με εργαλεία όπως Python, pandas και SQL.

Για τις ανάγκες της ανάλυσης, τα δεδομένα λήφθηκαν και αποθηκεύτηκαν σε κατάλληλη δομή φακέλων. Παράλληλα, εξετάστηκαν ζητήματα που σχετίζονται με την ακεραιότητα, την αξιοπιστία και την ιδιωτικότητα των δεδομένων. Σύμφωνα με την περιγραφή του case study, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που διασφαλίζει την προστασία προσωπικών δεδομένων και τη συμμόρφωση με τις πολιτικές απορρήτου.

Κατά τη φάση προετοιμασίας πραγματοποιήθηκε αρχικός έλεγχος της ακεραιότητας και της ποιότητας των δεδομένων. Μέσα από την προκαταρκτική διερεύνηση εντοπίστηκαν ορισμένες ελλειπείς τιμές (missing values), καθώς και πιθανά ασυνεπή ή μη έγκυρα δεδομένα σε συγκεκριμένα πεδία. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν αναλυτικότερα στη φάση επεξεργασίας και καθαρισμού των δεδομένων (Process Phase), με στόχο τη διασφάλιση της αξιοπιστίας της ανάλυσης.

Τα ιστορικά δεδομένα διαδρομών της Cyclistic παρέχουν πολύτιμες πληροφορίες σχετικά με τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων. Μέσα από δεδομένα όπως η διάρκεια διαδρομών, οι ώρες και ημέρες χρήσης, οι σταθμοί εκκίνησης και τερματισμού, καθώς και ο τύπος χρήστη, καθίσταται δυνατή η αναγνώριση διαφορών μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Η ανάλυση αυτών των προτύπων χρήσης συμβάλλει στην καλύτερη κατανόηση των συνηθειών των χρηστών και υποστηρίζει τη διαμόρφωση αποτελεσματικότερων στρατηγικών marketing για την αύξηση των ετήσιων συνδρομών.

Κατά την αρχική διερεύνηση των δεδομένων εντοπίστηκαν ορισμένα ζητήματα που θα μπορούσαν να επηρεάσουν την ανάλυση. Συγκεκριμένα, παρατηρήθηκαν ελλειπίες τιμές (missing values) σε ορισμένα πεδία, καθώς και πιθανές ασυνέπειες ή μη έγκυρες εγγραφές σε δεδομένα διαδρομών. Επιπλέον, λόγω περιορισμών που σχετίζονται με την προστασία προσωπικών δεδομένων, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που περιορίζει τη δυνατότητα βαθύτερης ανάλυσης της συμπεριφοράς των πελατών. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν κατά τις επόμενες φάσεις καθαρισμού και επεξεργασίας των δεδομένων.

Παρατίθεται ένα απόσπασμα από το αρχείο “Divvy_Trips_2019_Q1”:

trip_id	start_time	end_time	bikeid	tripduration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	gender	birthyear
21742443	2019-01-01 0:04:37	2019-01-01 0:11	2167	390	199	Wabash Ave & C	84	Milwaukee Ave & S	Subscriber	Male	1989
21742444	2019-01-01 0:08:13	2019-01-01 0:15	4386	441	44	State St & Rand	624	Dearborn St & V	Subscriber	Female	1990
21742445	2019-01-01 0:13:23	2019-01-01 0:27	1524	829	15	Racine Ave & 18	644	Western Ave & F	Subscriber	Female	1994
21742446	2019-01-01 0:13:45	2019-01-01 0:43	252	1,783.00	123	California Ave &	176	Clark St & Elm S	Subscriber	Male	1993
21742447	2019-01-01 0:14:52	2019-01-01 0:20	1170	364	173	Mies van der Ro	35	Streeter Dr & Gr	Subscriber	Male	1994
21742448	2019-01-01 0:15:33	2019-01-01 0:19	2437	216	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Female	1983
21742449	2019-01-01 0:16:06	2019-01-01 0:19	2708	177	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Male	1984
21742450	2019-01-01 0:18:41	2019-01-01 0:20	2796	100	211	St. Clair St & Eri	142	McClurg Ct & Er	Subscriber	Male	1990
21742451	2019-01-01 0:18:43	2019-01-01 0:47	6205	1,727.00	150	Fort Dearborn D	148	State St & 33rd S	Subscriber	Male	1995
21742452	2019-01-01 0:19:18	2019-01-01 0:24	3939	336	268	Lake Shore Dr &	141	Clark St & Lincol	Subscriber	Male	1996
21742453	2019-01-01 0:20:34	2019-01-01 0:35	6243	886	299	Halsted St & Ro	295	Broadway & Arg	Subscriber	Male	1994
21742454	2019-01-01 0:21:52	2019-01-01 0:32	6300	653	204	Prairie Ave & Ga	420	Ellis Ave & 55th	Subscriber	Female	1994
21742455	2019-01-01 0:23:04	2019-01-01 0:33	3029	601	90	Millennium Park	255	Indiana Ave & R	Subscriber	Male	1986
21742456	2019-01-01 0:23:43	2019-01-01 0:33	84	562	90	Millennium Park	255	Indiana Ave & R	Customer	Female	1990
21742457	2019-01-01 0:23:54	2019-01-01 0:39	5019	906	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742458	2019-01-01 0:24:08	2019-01-01 0:39	5526	892	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742459	2019-01-01 0:24:13	2019-01-01 0:31	3373	407	152	Lincoln Ave & Di	166	Ashland Ave & V	Subscriber	Male	1967
21742460	2019-01-01 0:24:27	2019-01-01 0:47	5777	1,356.00	268	Lake Shore Dr &	319	Greenview Ave & L	Customer	Female	1990
21742461	2019-01-01 0:25:28	2019-01-01 0:27	3940	102	35	Streeter Dr & Gr	35	Streeter Dr & Gr	Subscriber	Male	1985
21742463	2019-01-01 0:29:19	2019-01-01 1:08	3914	2,333.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742464	2019-01-01 0:29:21	2019-01-01 0:45	140	960	47	State St & Kinzie	111	Sedgwick St & H	Subscriber	Male	1957
21742465	2019-01-01 0:29:28	2019-01-01 1:07	3355	2,301.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742466	2019-01-01 0:29:47	2019-01-01 0:49	5026	1,168.00	85	Michigan Ave &	329	Lake Shore Dr &	Subscriber	Male	1959

4. Process Phase – Καθαρισμός και Επεξεργασία Δεδομένων

Η φάση “Process” επικεντρώνεται στον καθαρισμό, τον μετασχηματισμό και την προετοιμασία των δεδομένων, ώστε αυτά να είναι κατάλληλα για αξιόπιστη ανάλυση. Στο πλαίσιο της παρούσας μελέτης πραγματοποιήθηκε έλεγχος των δεδομένων για πιθανά σφάλματα, ελλιπείς τιμές, ασυνέπειες και μη έγκυρες εγγραφές, με στόχο τη διασφάλιση της ποιότητας και της αξιοπιστίας της ανάλυσης.

Για την επεξεργασία των δεδομένων χρησιμοποιήθηκαν εργαλεία όπως Python, pandas και υπολογιστικά φύλλα Excel/Google Sheets, καθώς τα εργαλεία αυτά παρέχουν ευελιξία και δυνατότητες αποτελεσματικής διαχείρισης μεγάλου όγκου δεδομένων. Τα αρχικά datasets αποσυμπίεστηκαν και οργανώθηκαν σε κατάλληλη δομή φακέλων, ενώ δημιουργήθηκαν ξεχωριστά υποσύνολα αρχείων για την αποθήκευση των πρωτογενών δεδομένων και των επεξεργασμένων εκδόσεών τους.

Στη συνέχεια πραγματοποιήθηκε μετασχηματισμός των δεδομένων μέσω της δημιουργίας νέων πεδίων που κρίθηκαν απαραίτητα για την ανάλυση. Συγκεκριμένα, δημιουργήθηκε το πεδίο `ride_length`, το οποίο υπολογίζει τη διάρκεια κάθε διαδρομής μέσω της διαφοράς μεταξύ της ώρας λήξης και της ώρας έναρξης της διαδρομής. Επιπλέον, δημιουργήθηκε το πεδίο `day_of_week`, το οποίο προσδιορίζει την ημέρα της εβδομάδας κατά την οποία πραγματοποιήθηκε κάθε διαδρομή, επιτρέποντας την ανάλυση προτύπων χρήσης ανά ημέρα.

Καταγραφή φάσης καθαρισμού και μετασχηματισμού δεδομένων

Στα πλαίσια αυτού του project χρησιμοποιούνται δύο αρχεία, τα `Divvy_Trips_2019_Q1` και `Divvy_Trips_2020_Q1`. Ξεκινάμε τον καθαρισμό δεδομένων από το `Divvy_Trips_2019_Q1`.

A) Το πρώτο πράγμα που ελέγχθηκε είναι το αν υπάρχουν διπλότυπες εγγραφές στο πεδίο `trip_id`, καθώς κάθε τιμή αυτού του πεδίου πρέπει να είναι μοναδική.

Δημιουργήσαμε μια προσωρινή στήλη `duplicate_check` στην οποία εφαρμόσαμε την φόρμουλα `COUNTIF(A:A, Ax)` όπου x ο αριθμός της εκάστοτε γραμμής. Ελέγχεται με αυτόν τον τρόπο το ενδεχόμενο κάποιο ID να εμφανίζεται πάνω από μία φορές στην στήλη `trip_id`. Δημιουργώντας ένα φίλτρο διαπιστώνουμε ότι η μόνη τιμή που υπάρχει στην στήλη `duplicate_check` είναι η τιμή 1 όπως φαίνεται και στην παρακάτω εικόνα. Συνεπώς, κάθε ID είναι μοναδικό και αποκλείεται το ενδεχόμενο διπλότυπου.

	M	N	O
	ride_length	day_of_week	uplicate_chec
9	Sort A to Z Sort Z to A Sort by colour Filter by colour Filter by condition Filter by values Select all 1 - Clear ✓ 1		
0			
4			
3			
4			
3			
4			
0			
5			
6			
4			
4			
6			
0			
9			
9			
7			

B) Εξετάζουμε το ενδεχόμενο να υπάρχουν τιμές αρνητικές ή μηδενικές στο πεδίο tripduration. Βάζουμε φίλτρο στην στήλη να εμφανιστούν οι εγγραφές που έχουν μηδενική ή αρνητική τιμή στο πεδίο αυτό και παρατηρούμε ότι δεν εμφανίζεται καμία εγγραφή όπως φαίνεται και στην παρακάτω εικόνα. Συνεπώς είμαστε εντάξει και με το εν λόγω πεδίο.

C	D	E	F	G	H	
end_time	bikeid	tripduration	om_station_i	n_station_na	to_station_id	to_sta
Sort A to Z Sort Z to A Sort by colour Filter by colour Filter by condition Less than or equal to 0 Filter by values Cancel OK						

Γ) Εξετάζουμε το ενδεχόμενο να υπάρχουν ελλιπείς τιμές (κενά) στα πεδία με την χρήση της συνάρτησης COUNTBLANK(). Διαπιστώθηκε ότι τα πεδία gender και birthyear έχουν 19.711 και 18.023 εγγραφές αντίστοιχα χωρίς τιμή. Αυτές οι μεταβλητές κρίθηκε ότι μπορούν να αξιοποιηθούν για την εξαγωγή δημογραφικών και marketing συμπερασμάτων σχετικά με τη συμπεριφορά των χρηστών. Για τον

λόγο αυτό αποφασίστηκε η αφαίρεση των εγγραφών που περιείχαν κενές τιμές στα συγκεκριμένα πεδία, ώστε το τελικό dataset να χαρακτηρίζεται από μεγαλύτερη πληρότητα, συνέπεια και αξιοπιστία ως προς τα δημογραφικά χαρακτηριστικά των χρηστών. Η διαδικασία πραγματοποιήθηκε μέσω εφαρμογής φίλτρων στις αντίστοιχες στήλες με συνθήκη “Is empty” και στη συνέχεια διαγράφηκαν οι αντίστοιχες γραμμές από το dataset.

1	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
	trip_id	start_time	end_time	bikeid	tripduration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	gender	birthyear	ride_length	day_of_week	count_blank
2	21742443	2019-01-01 04:37	2019-01-01 11:07	2167	390	199	Wabash Ave & Grand Ave	84	Milwaukee Ave & Grand Ave	Subscriber	Male	1989	0 06:30	3	
3	21742444	2019-01-01 08:13	2019-01-01 15:34	4386	441	44	State St & Randolph St	624	Dearborn St & Van Buren St (*)	Subscriber	Female	1990	0 07:21	3	TRIP_ID
4	21742445	2019-01-01 01:13	2019-01-01 02:12	1524	829	15	Racine Ave & 18th St	644	Western Ave & Fillmore St (*)	Subscriber	Female	1994	0 13:49	3	0
5	21742446	2019-01-01 01:13	2019-01-01 04:38	252	1,783.00	123	California Ave & Milwaukee Ave	176	Clark St & Elm St	Subscriber	Male	1993	0 29:43	3	
6	21742447	2019-01-01 01:14	2019-01-01 02:56	1170	364	173	Mies van der Rohe Way & Chicago Ave	35	Streeter Dr & Grand Ave	Subscriber	Male	1994	0 06:04	3	START_TIME
7	21742448	2019-01-01 01:15	2019-01-01 01:19	2437	216	90	LaSalle St & Washington St	49	Dearborn St & Monroe St	Subscriber	Female	1963	0 03:36	3	0
8	21742449	2019-01-01 01:19	2019-01-01 01:19	2768	177	90	LaSalle St & Washington St	49	Dearborn St & Monroe St	Subscriber	Male	1964	0 02:57	3	
9	21742450	2019-01-01 01:18	2019-01-01 02:21	2796	100	211	St. Clair St & Erie St	142	McClurg Ct & Erie St	Subscriber	Male	1990	0 01:40	3	END_TIME
10	21742451	2019-01-01 01:18	2019-01-01 04:30	6205	1,727.00	150	Fort Dearborn Dr & 31st St	148	State St & 33rd St	Subscriber	Male	1995	0 28:47	3	0
11	21742452	2019-01-01 01:19	2019-01-01 02:54	3939	336	268	Lake Shore Dr & North Blvd	141	Clark St & Lincoln Ave	Subscriber	Male	1996	0 05:36	3	
12	21742453	2019-01-01 02:30	2019-01-01 03:50	6243	886	299	Halsted St & Roscoe St	295	Broadway & Argyle St	Subscriber	Male	1994	0 14:46	3	BIKEID
13	21742454	2019-01-01 02:51	2019-01-01 03:45	6300	653	204	Prairie Ave & Garfield Blvd	420	Ellis Ave & 55th St	Subscriber	Female	1994	0 10:53	3	0
14	21742455	2019-01-01 02:53	2019-01-01 03:35	3029	601	90	Millennium Park	255	Indiana Ave & Roosevelt Rd	Subscriber	Male	1986	0 10:01	3	
15	21742456	2019-01-01 02:53	2019-01-01 03:35	84	562	90	Millennium Park	255	Indiana Ave & Roosevelt Rd	Customer	Female	1990	0 09:22	3	TRIPDURATION
16	21742457	2019-01-01 02:54	2019-01-01 03:39	5019	906	289	Wells St & Concord Ln	324	Stockton Dr & Wrigthwood Ave	Subscriber	Female	1989	0 15:06	3	0
17	21742458	2019-01-01 02:54	2019-01-01 03:39	5526	892	289	Wells St & Concord Ln	324	Stockton Dr & Wrigthwood Ave	Subscriber	Female	1989	0 14:52	3	FROM_STATION_ID
18	21742459	2019-01-01 02:54	2019-01-01 03:39	3373	407	152	Lincoln Ave & Diversey Pkwy	166	Ashland Ave & Wrigthwood Ave	Subscriber	Male	1967	0 06:47	3	0
19	21742460	2019-01-01 02:54	2019-01-01 04:03	5777	1,356.00	268	Lake Shore Dr & North Blvd	319	Greenview Ave & Diversey Pkwy	Customer	Female	1990	0 22:36	3	
20	21742461	2019-01-01 02:55	2019-01-01 02:55	3940	102	35	Streeter Dr & Grand Ave	35	Streeter Dr & Grand Ave	Subscriber	Male	1985	0 01:42	3	0
21	21742464	2019-01-01 02:59	2019-01-01 04:52	140	960	47	State St & Kinzie St	111	Sedgwick St & Huron St	Subscriber	Male	1957	0 16:00	3	
22	21742465	2019-01-01 02:59	2019-01-01 07:49	3355	2,301.00	35	Streeter Dr & Grand Ave	39	Wabash Ave & Adams St	Customer			0 38:21	3	0
23	21742466	2019-01-01 02:59	2019-01-01 04:15	5026	1,168.00	85	Michigan Ave & Oak St	329	Lake Shore Dr & Diversey Pkwy	Subscriber	Male	1959	0 19:28	3	TO_STATION_NAME
24	21742467	2019-01-01 03:30	2019-01-01 03:42	1998	474	289	Wells St & Concord Ln	313	Lakeview Ave & Fullerton Pkwy	Subscriber	Male	1994	0 07:54	3	0
25	21742468	2019-01-01 03:30	2019-01-01 05:25	2630	1,036.00	13	Wilton Ave & Diversey Pkwy	61	Wood St & Milwaukee Ave	Subscriber	Male	1991	0 17:16	3	
26	21742469	2019-01-01 03:34	2019-01-01 03:25	3722	230	520	Greenview Ave & Jarvis Ave	523	Eastlake Ter & Rogers Ave	Subscriber	Male	1961	0 03:50	3	USERTYPE
27	21742471	2019-01-01 03:38	2019-01-01 05:38	1166	747	256	Broadway & Sheridan Rd	297	Paulina St & Montrose Ave	Subscriber	Male	1968	0 12:27	3	0
28	21742472	2019-01-01 03:38	2019-01-01 05:38	1704	711	256	Broadway & Sheridan Rd	297	Paulina St & Montrose Ave	Subscriber	Male	1964	0 11:51	3	
29	21742473	2019-01-01 04:10	2019-01-01 04:29	1476	553	254	Pine Grove Ave & Irving Park Rd	465	Marine Dr & Ainslie St	Subscriber	Male	1990	0 09:13	3	GENDER
30	21742474	2019-01-01 04:41	2019-01-01 05:27	4614	521	66	Clinton St & Lake St	52	Michigan Ave & Lake St	Subscriber	Male	1994	0 08:41	3	19711
31	21742475	2019-01-01 04:53	2019-01-01 17:51	5583	1,934.00	464	Damen Ave & Foster Ave	30	Ashland Ave & Augusta Blvd	Subscriber	Male	1991	0 32:14	3	
32	21742476	2019-01-01 04:55	2019-01-01 05:00	1158	255	418	Ellis Ave & 53rd St	121	Blackstone Ave & Hyde Park Blvd	Subscriber	Male	1988	0 04:15	3	BIRTHYEAR
33	21742477	2019-01-01 04:56	2019-01-01 05:12	2314	307	144	Larrabee St & Webster Ave	313	Lakeview Ave & Fullerton Pkwy	Subscriber	Female	1961	0 05:07	3	18023
34	21742478	2019-01-01 04:57	2019-01-01 05:46	1411	427	253	Wentworth Ave & Lawrence Ave	463	Clark St & Benveny Ave	Subscriber	Male	1984	0 07:07	3	
35	21742479	2019-01-01 04:58	2019-01-01 05:39	6336	655	304	Broadway & Waveland Ave	332	Burling St (Halsted) & Diversey Pkwy (Temp)	Subscriber	Male	1988	0 10:55	3	RIDE_LENGTH
36	21742480	2019-01-01 05:15	2019-01-01 05:49	5629	174	206	Halsted St & Archer Ave	135	Halsted St & 21st St	Subscriber	Male	1989	0 02:54	3	0
37	21742481	2019-01-01 05:35	2019-01-01 05:35	5248	120	522	Bosworth Ave & Howard St	520	Greenview Ave & Jarvis Ave	Subscriber	Male	1976	0 02:00	3	
38	21742483	2019-01-01 05:39	2019-01-01 11:53	5075	1,844.00	144	Larrabee St & Webster Ave	165	State St & Armitage Ave	Subscriber	Male	1989	0 17:24	3	DAY_OF_WEEK
39	21742484	2019-01-01 05:39	2019-01-01 10:57	6312	404	193	State St & 29th St	120	Wentworth Ave & Cermak Rd (Temp)	Subscriber	Male	1992	0 06:44	3	0
40	21742485	2019-01-01 05:44	2019-01-01 10:45	781	541	200	Kedzie Ave & Milwaukee Ave	507	Humboldt Blvd & Armitage Ave	Subscriber	Male	1968	0 09:01	3	
41	21742486	2019-01-01 05:55	2019-01-01 10:50	2448	535	260	Kedzie Ave & Milwaukee Ave	507	Humboldt Blvd & Armitage Ave	Subscriber	Female	1988	0 08:55	3	

Δ) Ελέγχουμε τις τιμές του πεδίου ride_length, δηλαδή την διάρκεια κάθε διαδρομής για ακραίες τιμές (outliers).

Εφαρμόζοντας φθίνουσα ταξινόμηση στις εγγραφές βάσει του εν λόγω πεδίου, διαπιστώνουμε ότι υπάρχουν πλειάδες που έχουν παράλογες για την φύση του αντικειμένου τιμές, δηλαδή κάποιες διαδρομές είναι πολύ μεγάλης διάρκειας. Λήφθηκε η απόφαση όσες εγγραφές έχουν τιμή ride_length μεγαλύτερη της μίας ώρας να διαγραφούν, καθώς θεωρούνται άκυρες. Μόλις περίπου 1.900 τέτοιες εγγραφές υπάρχουν στις προσεγγιστικά 350 χιλιάδες που έχει συνολικά το αρχείο. Πιθανότατα πρόκειται για διαδρομές τις οποίες οι χρήστες ξέχασαν να τερματίσουν.

Εφαρμόστηκε και αύξουσα ταξινόμηση για να ελέγξουμε αν υπάρχουν παράλογα μικρές τιμές στο πεδίο αυτό. Η μικρότερη διάρκεια που υπάρχει στο αρχείο είναι 1 λεπτό και 1 δευτερόλεπτο, την οποία θεωρούμε λογική.

Ε) Ελέγχουμε για ακραίες τιμές (outliers) και στις τιμές του πεδίου birthyear. Υπενθυμίζουμε ότι το αρχείο έχει εγγραφές από το έτος 2019.


Εφαρμόζουμε φθίνουσα ταξινόμηση στο εν λόγω πεδίο και παρατηρούμε ότι η πιο μεγάλη τιμή του πεδίου είναι η 2003. Η χρονολογία αυτή θεωρείται αποδεκτή, καθώς ένα άτομο 16 ετών μπορεί να νοικιάσει ποδήλατο.

Εφαρμόζουμε τώρα αύξουσα ταξινόμηση στο εν λόγω πεδίο και παρατηρούμε πληθώρα εγγραφών που έχουν τιμή παράλογη.

station	to_station_name	usertype	gender	birthyear	ride_length	day_of_week
213	Leavitt St & North Ave	Subscriber	Male	1900	0:01:15	6
66	Clinton St & Lake St	Subscriber	Male	1900	0:01:47	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:06	2
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:06	1
61	Wood St & Milwaukee Ave	Subscriber	Male	1900	0:03:15	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:21	4
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:23	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:24	4
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:32	1
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:33	4
213	Leavitt St & North Ave	Subscriber	Male	1900	0:03:38	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:52	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:04	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:10	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:11	7
213	Leavitt St & North Ave	Subscriber	Male	1900	0:04:14	1
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:19	1
158	Milwaukee Ave & Wabansia Ave	Subscriber	Male	1900	0:04:23	6
159	Claremont Ave & Hirsch St	Subscriber	Male	1900	0:04:25	3
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:30	6
213	Leavitt St & North Ave	Subscriber	Male	1900	0:05:04	1
158	Milwaukee Ave & Wabansia Ave	Subscriber	Male	1900	0:05:52	4
509	Troy St & North Ave	Subscriber	Male	1900	0:06:26	5
334	Lake Shore Dr & Belmont Ave	Subscriber	Male	1900	0:06:57	7

Όπως φαίνεται στην παραπάνω εικόνα, υπάρχουν εγγραφές που έχουν ως ημερομηνία γέννησης το έτος 1.900. Προφανώς η τιμή αυτή είναι άκυρη. Θέτουμε ως λογικό όριο στο πεδίο αυτό την χρονολογία 1939, και σβήνουμε όλες τις εγγραφές που έχουν παλαιότερη (183 εγγραφές).

Ζ) Τέλος, κάνουμε έναν έλεγχο ότι τα πεδία usertype και gender έχουν αποδεκτές τιμές. Εφαρμόζουμε φίλτρο και ελέγχουμε τις υπάρχουσες τιμές. Διαπιστώνουμε ότι και τα δύο πεδία είναι εντάξει.



Στην συνέχεια εξετάζουμε το αρχείο Divvy_Trips_2020_Q1.

Κατά την εξέταση των datasets Divvy_Trips_2019_Q1 και Divvy_Trips_2020_Q1 διαπιστώθηκαν σημαντικές διαφορές τόσο στη δομή όσο και στο περιεχόμενο των δεδομένων. Συγκεκριμένα, το dataset του 2019 χρησιμοποιεί το πεδίο trip_id με αριθμητικές τιμές, ενώ στο dataset του 2020 το αντίστοιχο πεδίο ονομάζεται ride_id και περιλαμβάνει αλφαριθμητικές τιμές. Επιπλέον, τα πεδία start_time και end_time του 2019 αντικαθίστανται από τα started_at και ended_at στο dataset του 2020. Παρατηρείται επίσης αλλαγή στο πεδίο κατηγοριοποίησης των χρηστών, καθώς το usertype με τιμές Subscriber και Customer αντικαθίσταται από το member_casual με τιμές member και casual. Το dataset του 2019 περιλαμβάνει δημογραφικά στοιχεία όπως gender και birthyear, τα οποία απουσιάζουν πλήρως από το dataset του 2020. Αντίθετα, το dataset του 2020 περιέχει επιπλέον πληροφορίες όπως το πεδίο rideable_type και γεωγραφικές συντεταγμένες (start_lat, start_lng, end_lat, end_lng), οι οποίες δεν υπάρχουν στο dataset του 2019. Τέλος, στο dataset του 2019 η διάρκεια διαδρομής παρέχεται έτοιμη μέσω του πεδίου tripduration, ενώ στο dataset του 2020 απαιτείται υπολογισμός της διάρκειας από τα χρονικά πεδία έναρξης και λήξης της διαδρομής. Παρατίθεται απόσπασμα του αρχείου 2020 για κατανόηση του schema του:

ride_id	rideable_type	started_at	ended_at	start_station_name	start_station	end_station_name	end_station	start_lat	start_lng	end_lat	end_lng	member_casual
EACB19130B0CDA4A	docked_bike	2020-01-21 20:06:59	2020-01-21 20:14:30	Western Ave & Leland Ave	239	Clark St & Leland Ave	326	41.9665	-87.6884	41.9671	-87.6674	member
8FED874C809DC021	docked_bike	2020-01-30 14:22:39	2020-01-30 14:26:22	Clark St & Montrose Ave	234	Southport Ave & Irving Park Rd	318	41.9616	-87.6666	41.9542	-87.6644	member
789F3C21E472CA96	docked_bike	2020-01-09 19:29:26	2020-01-09 19:32:17	Broadway & Belmont Ave	296	Wilton Ave & Belmont Ave	117	41.9401	-87.6455	41.9402	-87.653	member
C9A388DAC6ABF313	docked_bike	2020-01-06 16:17:07	2020-01-06 16:25:56	Clark St & Randolph St	51	Fairbanks Ct & Grand Ave	24	41.8846	-87.6319	41.8918	-87.6206	member
9438C3CBCECFD662	docked_bike	2020-01-30 8:37:16	2020-01-30 8:42:48	Clinton St & Lake St	66	Wells St & Hubbard St	212	41.8856	-87.6418	41.8899	-87.6343	member
6D9C8A6938165C11	docked_bike	2020-01-10 12:33:05	2020-01-10 12:37:54	Wells St & Hubbard St	212	Desplaines St & Randolph St	96	41.8899	-87.6343	41.8846	-87.6446	member
31EB9B8F406D4C82	docked_bike	2020-01-10 13:07:35	2020-01-10 13:12:24	Desplaines St & Randolph St	96	Wells St & Hubbard St	212	41.8846	-87.6446	41.8899	-87.6343	member
A2B24E3FC9C9720E3	docked_bike	2020-01-10 7:24:53	2020-01-10 7:29:50	Desplaines St & Randolph St	96	Wells St & Hubbard St	212	41.8846	-87.6446	41.8899	-87.6343	member
5E3F01E1441730B7	docked_bike	2020-01-31 16:37:16	2020-01-31 16:42:11	Wells St & Hubbard St	212	Desplaines St & Randolph St	96	41.8899	-87.6343	41.8846	-87.6446	member
19DC57F7E3140131	docked_bike	2020-01-31 9:39:17	2020-01-31 9:42:40	Clark St & Lake St	38	Orleans St & Merchandise Mart Plaza	100	41.886	-87.6309	41.8882	-87.6364	member
8639202D09FD9A41	docked_bike	2020-01-07 22:46:52	2020-01-07 22:50:08	Wilton Ave & Belmont Ave	117	Clark St & Newport St	632	41.9402	-87.653	41.9445	-87.6547	member
9E74E3BBAFFAB93A	docked_bike	2020-01-08 16:02:44	2020-01-08 16:09:04	LaSalle St & Illinois St	181	Clinton St & Washington Blvd	91	41.8908	-87.6317	41.8834	-87.6412	member
3B8B2E2F29B63597	docked_bike	2020-01-08 9:33:13	2020-01-08 9:42:02	Clinton St & Washington Blvd	91	LaSalle St & Illinois St	181	41.8834	-87.6412	41.8908	-87.6317	member
0F8517F8D21287D2	docked_bike	2020-01-23 9:38:11	2020-01-23 9:45:56	Clinton St & Washington Blvd	91	LaSalle St & Illinois St	181	41.8834	-87.6412	41.8908	-87.6317	member
15A9163FAEC2641	docked_bike	2020-01-28 20:52:50	2020-01-28 21:09:30	California Ave & Milwaukee Ave	123	Marshfield Ave & Cortland St	58	41.9227	-87.6972	41.916	-87.6689	member
E45104F1ED756AF7	docked_bike	2020-01-07 17:06:14	2020-01-07 17:42:01	Franklin St & Jackson Blvd	152	Lincoln Ave & Diversey Pkwy	36	41.8777	-87.6353	41.9322	-87.6586	member
219541294624C4B7	docked_bike	2020-01-07 8:38:55	2020-01-07 9:11:40	Wilton Ave & Diversey Pkwy	13	Franklin St & Jackson Blvd	36	41.9324	-87.6527	41.8777	-87.6353	member
013862D47804B9A4	docked_bike	2020-01-06 17:16:14	2020-01-06 17:48:21	Franklin St & Jackson Blvd	152	Lincoln Ave & Diversey Pkwy	36	41.8777	-87.6353	41.9322	-87.6586	member
00678BBA48438651	docked_bike	2020-01-06 8:44:31	2020-01-06 9:21:28	Lincoln Ave & Diversey Pkwy	152	Franklin St & Jackson Blvd	36	41.9322	-87.6586	41.8777	-87.6353	member
A854F8161B5A5C0	docked_bike	2020-01-19 12:04:10	2020-01-19 12:10:18	Kingsbury St & Kinzie St	133	Clark St & Chicago Ave	337	41.8892	-87.6385	41.8968	-87.6309	member
3479141FF24AD595	docked_bike	2020-01-16 17:10:39	2020-01-16 17:40:40	Lake Shore Dr & Monroe St	76	Michigan Ave & Washington St	43	41.881	-87.6167	41.884	-87.6247	casual
81D44C3E2353F9BE	docked_bike	2020-01-08 15:47:42	2020-01-08 15:58:40	Canal St & Adams St	192	Michigan Ave & Washington St	43	41.8793	-87.6399	41.884	-87.6247	member
1AA1BF54DC4A8636	docked_bike	2020-01-08 6:29:01	2020-01-08 6:50:02	Indiana Ave & Roosevelt Rd	255	Canal St & Adams St	192	41.8679	-87.623	41.8793	-87.6399	member
FF5FB29D0CF841C9F3	docked_bike	2020-01-08 7:30:59	2020-01-08 7:33:54	Broadway & Sheridan Rd	240	Michigan Ave & Irving Park Rd	240	41.9528	-87.65	41.9542	-87.6544	member
869F3756B34163BA	docked_bike	2020-01-23 15:23:54	2020-01-23 15:37:37	Desplaines St & Jackson Blvd	107	Michigan Ave & Washington St	43	41.8783	-87.6439	41.884	-87.6247	member
09EDF290239E4843	docked_bike	2020-01-23 14:59:58	2020-01-23 15:02:49	Canal St & Adams St	192	Desplaines St & Jackson Blvd	107	41.8793	-87.6399	41.8783	-87.6439	member
CABE2F9EB7A7639C	docked_bike	2020-01-11 14:45:48	2020-01-11 14:58:46	Western Ave & Division St	305	Wood St & Hubbard St	285	41.9029	-87.6873	41.8899	-87.6715	member
7996062626A55CEFF	docked_bike	2020-01-17 13:44:55	2020-01-17 13:48:33	Franklin St & Jackson Blvd	36	Wells St & Polk St	175	41.8777	-87.6353	41.8726	-87.6335	member
142E7C9831AE8D5D	docked_bike	2020-01-08 8:23:41	2020-01-08 8:36:31	Dearborn St & Erie St	110	Franklin St & Adams St (Temp)	286	41.894	-87.6293	41.8794	-87.6355	member
82061D73814586B2	docked_bike	2020-01-08 16:22:13	2020-01-08 16:30:43	Franklin St & Jackson Blvd	36	Green St & Madison St	198	41.8777	-87.6353	41.8819	-87.6488	member
85E28F761B23E62A	docked_bike	2020-01-03 11:58:12	2020-01-03 12:05:01	Burling St (Halsted) & Diversey Pkwy (Temp)	332	Clark St & Newport St	632	41.9331	-87.6478	41.9445	-87.6547	member
8E276833CE7897DAF	docked_bike	2020-01-03 11:38:04	2020-01-03 11:40:36	Wilton Ave & Diversey Pkwy	13	Halsted St & Wrightwood Ave	349	41.9324	-87.6527	41.9291	-87.6491	member
46A777303CE7C883	docked_bike	2020-01-03 9:38:11	2020-01-03 9:43:52	Clark St & Newport St	632	Wilton Ave & Diversey Pkwy	13	41.9445	-87.6547	41.9324	-87.6527	member
CDA4546AFB8F34F5	docked_bike	2020-01-05 13:54:08	2020-01-05 14:24:03	Logan Blvd & Elston Ave	258	Stockton Dr & Wrightwood Ave	324	41.9295	-87.6842	41.9313	-87.6387	casual

Κρίνεται σκόπιμη η ενοποίηση των datasets Divvy_Trips_2019_Q1 και Divvy_Trips_2020_Q1, με στόχο τη δημιουργία ενός μεγαλύτερου και περισσότερο αντιπροσωπευτικού συνόλου δεδομένων για την ανάλυση της συμπεριφοράς των χρηστών της υπηρεσίας Cyclistic. Η συνένωση των δύο αρχείων αναμένεται να προσφέρει πληρέστερη εικόνα σχετικά με τα πρότυπα χρήσης των ποδηλάτων και να οδηγήσει σε πιο αξιόπιστα στατιστικά συμπεράσματα. Ωστόσο, πριν από την ενοποίηση των δεδομένων, λόγω του ότι υπάρχουν σημαντικές διαφοροποιήσεις στη δομή, στη μορφή και στην ονοματοδοσία ορισμένων πεδίων μεταξύ των δύο datasets, απαιτείται να γίνει διαδικασία προσαρμογής και εναρμόνισης των δεδομένων, ώστε να διασφαλιστεί η συμβατότητα και η ομοιομορφία του τελικού συνόλου δεδομένων που θα χρησιμοποιηθεί στην ανάλυση.

Για να είναι συμβατά τα δύο αυτά datasets, αλλά και για να καθαριστεί το αρχείο 2020, αποφασίστηκαν οι εξής ενέργειες:

A) Διαγραφή των πεδίων bike_id, trip_id και ride_id. Τα IDs χρησιμεύουν μόνο ως μοναδικοί αναγνωριστές και δεν προσφέρουν αναλυτική πληροφορία, ειδικά από την στιγμή που διαθέτουμε τα ονόματα των σταθμών. Επιπρόσθετα, τα IDs δεν χρησιμοποιούνται σε aggregations ή comparisons.

Στα ονόματα των σταθμών του αρχείου 2020 παρατηρήθηκε ότι υπάρχουν οι τιμές “HQ QR” και “HUBBARD ST BIKE CHECKING (LBS-WH-TEST)”. Οι εγγραφές αυτές, περίπου 10, διαγράφηκαν.

B) Διαγραφή του πεδίου rideable_type. Η μόνη τιμή του πεδίου αυτού είναι “docked_bike”. Το πεδίο αυτό δεν προσφέρει πληροφορία για την ανάλυση που θέλουμε να κάνουμε.

Γ) Διατήρηση των πεδίων `started_at`, `ended_at` και μετονομασία τους σε `start_time` και `end_time` όπως είναι στο αρχείο 2019. Επιπρόσθετα, θα προστεθούν στο 2020 τα πεδία `tripduration`, `ride_length` και `day_of_week` διότι είναι χρήσιμα για `duration analysis`, `weekday analysis` και `usage patterns`, πληροφορία η οποία είναι σημαντική για το έργο μας. Τέλος, τα `start_station_name` και `end_station_name` του αρχείου 2020 γίνονται `from_station_name` και `to_station_name`, και τα `start_station_id` και `end_station_id` μετονομάζονται σε `from_station_id` και `to_station_id`.

Παρατηρούμε ότι ορισμένες εγγραφές έχουν `end_time < start_time`, δηλαδή αρνητικό `tripduration`. Αυτές οι εγγραφές διαγράφονται. Επίσης, κατά αντιστοιχία με το αρχείο 2019 σβήνουμε ακραία μεγάλες χρονικές διάρκειες, δηλαδή όσες είναι πάνω από μία ώρα.

Στο εν λόγω αρχείο παρατηρούμε κάτι που δεν υπήρχε στο αρχείο 2019. Παρατηρούμε πολύ μικρές χρονικές διάρκειες. Υπάρχουν εγγραφές ακόμα και με μηδενική χρονική διάρκεια. Σβήνουμε όλες τις εγγραφές που έχουν χρονική διάρκεια μικρότερη του ενός λεπτού, καθώς θεωρούνται άκυρες.

Δ) Μετατροπή των τιμών `member` και `casual` του 2020 σε `Subscriber` και `Customer`.

Ε) Διαγραφή των πεδίων `birthyear` και `gender` από το dataset του 2019, καθώς τα συγκεκριμένα πεδία δεν υπάρχουν στο dataset του 2020 και επομένως δεν μπορούν να αξιοποιηθούν με συνέπεια στο ενοποιημένο σύνολο δεδομένων. Η διατήρησή τους θα δημιουργούσε ασυμβατότητα μεταξύ των δύο datasets και θα δυσχέραινε τη διαδικασία ενοποίησης και ανάλυσης. Επιπλέον, η παρούσα μελέτη επικεντρώνεται κυρίως στη συμπεριφορά χρήσης της υπηρεσίας από διαφορετικούς τύπους χρηστών και όχι στη δημογραφική ανάλυση των πελατών. Για τον λόγο αυτό κρίθηκε καταλληλότερη η αφαίρεση των συγκεκριμένων πεδίων, ώστε να διατηρηθεί κοινή και ομοιόμορφη δομή δεδομένων μεταξύ των δύο χρονικών περιόδων. Είναι προφανές ότι ήταν εντέλει περιττή η οποία επεξεργασία είχαν υποστεί τα πεδία αυτά κατά τον καθαρισμό του αρχείου 2019.

ΣΤ) Τέλος, γίνεται έλεγχος με χρήση φίλτρων για κενές ή άκυρες τιμές στα πεδία. Δεν εντοπίζεται κάποιο σφάλμα.

Παρατίθεται η τελική μορφή των δεδομένων των αρχείων 2019 και 2020:

	A	B	C	D	E	F	G	H	I	J
	start_time	end_time	trip_duration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	ride_length	day_of_week
1	2020-02-13 16:45:42	2020-02-13 16:46:42	60	199	Wabash Ave & Grand Ave	199	Wabash Ave & Grand Ave	Subscriber	0:01:00	5
2	2020-02-23 21:45:41	2020-02-23 21:46:41	60	223	Clifton Ave & Armitage Ave	223	Clifton Ave & Armitage Ave	Subscriber	0:01:00	1
3	2020-02-13 7:55:55	2020-02-13 7:56:55	60	192	Canal St & Adams St	192	Canal St & Adams St	Subscriber	0:01:00	5
4	2020-02-26 17:11:55	2020-02-26 17:12:55	60	133	Kingsbury St & Kinzie St	133	Kingsbury St & Kinzie St	Subscriber	0:01:00	4
5	2020-02-14 8:39:46	2020-02-14 8:39:46	60	91	Clinton St & Washington Blvd	91	Clinton St & Washington Blvd	Subscriber	0:01:00	6
6	2020-02-13 7:51:05	2020-02-13 7:52:05	60	192	Canal St & Adams St	192	Canal St & Adams St	Subscriber	0:01:00	5
7	2020-03-12 10:10:55	2020-03-12 10:11:55	60	220	Clark St & Drummond Pl	220	Clark St & Drummond Pl	Subscriber	0:01:00	5
8	2020-01-26 1:51:36	2020-01-26 1:52:36	60	41	Federal St & Polk St	394	Clark St & 9th St (AMLJ)	Subscriber	0:01:00	1
9	2020-01-07 15:56:04	2020-01-07 15:57:04	60	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:00	3
10	2020-01-15 16:21:24	2020-01-15 16:22:24	60	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:00	4
11	2020-01-08 7:57:22	2020-01-08 7:58:22	60	291	Wells St & Evergreen Ave	291	Wells St & Evergreen Ave	Subscriber	0:01:00	4
12	2020-01-08 7:15:45	2020-01-08 7:16:45	60	91	Clinton St & Washington Blvd	77	Clinton St & Madison St	Subscriber	0:01:00	4
13	2020-01-07 7:15:20	2020-01-07 7:16:20	60	14	Morgan St & 18th St	14	Morgan St & 18th St	Subscriber	0:01:00	3
14	2020-01-27 8:00:10	2020-01-27 8:01:10	60	198	Green St & Madison St	198	Green St & Madison St	Subscriber	0:01:00	2
15	2020-01-15 17:38:00	2020-01-15 17:39:00	60	164	Franklin St & Lake St	164	Franklin St & Lake St	Subscriber	0:01:00	4
16	2020-01-06 13:15:09	2020-01-06 13:16:09	60	197	Michigan Ave & Madison St	197	Michigan Ave & Madison St	Subscriber	0:01:00	2
17	2020-01-10 16:38:17	2020-01-10 16:39:17	60	238	Wolcott (Ravenswood) Ave & Montrose Ave	238	Wolcott (Ravenswood) Ave & Montrose Ave	Subscriber	0:01:00	6
18	2020-02-04 7:45:59	2020-02-04 7:46:59	60	638	Clinton St & Jackson Blvd	638	Clinton St & Jackson Blvd	Subscriber	0:01:00	3
19	2020-02-19 18:38:22	2020-02-19 18:39:22	60	91	Clinton St & Washington Blvd	174	Canal St & Madison St	Subscriber	0:01:00	4
20	2020-02-10 17:04:22	2020-02-10 17:05:22	60	622	California Ave & Cortez St	622	California Ave & Cortez St	Subscriber	0:01:00	2
21	2020-02-16 11:26:36	2020-02-16 11:27:36	60	225	Halsted St & Dickens Ave	225	Halsted St & Dickens Ave	Subscriber	0:01:00	1
22	2020-03-19 12:35:03	2020-03-19 12:36:03	60	254	Pine Grove Ave & Inng Park Rd	254	Pine Grove Ave & Inng Park Rd	Subscriber	0:01:00	5
23	2020-03-24 20:14:32	2020-03-24 20:15:32	60	340	Clark St & Wrightwood Ave	220	Clark St & Drummond Pl	Subscriber	0:01:00	3
24	2020-03-05 17:15:10	2020-03-05 17:16:10	60	350	Ashland Ave & Chicago Ave	350	Ashland Ave & Chicago Ave	Subscriber	0:01:00	5
25	2020-03-21 19:09:06	2020-03-21 19:10:06	60	112	Green St & Randolph St	198	Green St & Madison St	Subscriber	0:01:00	7
26	2020-01-21 16:49:15	2020-01-21 16:50:15	61	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:01	3
27	2020-01-28 16:42:58	2020-01-28 16:43:58	61	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:01	3
28	2020-01-03 22:46:27	2020-01-03 22:47:27	61	230	Lincoln Ave & Roscoe St	230	Lincoln Ave & Roscoe St	Subscriber	0:01:01	6
29	2020-02-20 19:16:42	2020-02-20 19:17:42	61	159	Claremont Ave & Hirsch St	159	Claremont Ave & Hirsch St	Subscriber	0:01:01	5
30	2020-02-04 9:10:53	2020-02-04 9:11:54	61	302	Sheffield Ave & Wrightwood Ave	67	Sheffield Ave & Fullerton Ave	Subscriber	0:01:01	3
31	2020-02-14 15:46:45	2020-02-14 15:47:46	61	283	LaSalle St & Jackson Blvd	283	LaSalle St & Jackson Blvd	Subscriber	0:01:01	6
32	2020-02-26 16:31:53	2020-02-26 16:32:54	61	100	Orleans St & Merchandise Mart Plaza	100	Orleans St & Merchandise Mart Plaza	Subscriber	0:01:01	4
33	2020-03-04 18:56:29	2020-03-04 18:57:30	61	302	Sheffield Ave & Wrightwood Ave	302	Sheffield Ave & Wrightwood Ave	Subscriber	0:01:01	4
34	2020-03-20 18:35:23	2020-03-20 18:36:24	61	48	Larrabee St & Kingsbury St	364	Larrabee St & Oak St	Subscriber	0:01:01	6
35	2020-03-26 10:43:56	2020-03-26 10:44:57	61	226	Racine Ave & Belmont Ave	226	Racine Ave & Belmont Ave	Subscriber	0:01:01	5
36	2020-03-08 18:12:37	2020-03-08 18:13:38	61	21	Aberdeen St & Jackson Blvd	21	Aberdeen St & Jackson Blvd	Subscriber	0:01:01	1
37	2020-03-05 8:17:50	2020-03-05 8:18:51	61	401	Shields Ave & 28th Pl	401	Shields Ave & 28th Pl	Subscriber	0:01:01	5
38	2020-03-12 7:15:05	2020-03-12 7:16:06	61	88	Racine Ave & Randolph St	621	Aberdeen St & Randolph St	Subscriber	0:01:01	5
39	2020-03-07 14:31:04	2020-03-07 14:32:05	61	35	Streeter Dr & Grand Ave	35	Streeter Dr & Grand Ave	Subscriber	0:01:01	7
40	2020-03-08 16:17:08	2020-03-08 16:18:09	61	6	Dusable Harbor	6	Dusable Harbor	Subscriber	0:01:01	1
41	2020-03-09 8:57:17	2020-03-09 8:58:18	61	7	Field Blvd & South Water St	7	Field Blvd & South Water St	Subscriber	0:01:01	2
42	2020-01-17 19:05:12	2020-01-17 19:06:13	61	342	Wolcott Ave & Polk St	342	Wolcott Ave & Polk St	Subscriber	0:01:01	6
43	2020-01-17 19:05:12	2020-01-17 19:06:13	61	342	Wolcott Ave & Polk St	342	Wolcott Ave & Polk St	Subscriber	0:01:01	6

Αντιγράφουμε τα δεδομένα του 2019 στο 2020 και δημιουργείται το τελικό αρχείο “Divvy_Trips_final” με 754.966 έγκυρες εγγραφές [3].

5. Analyze Phase – Ανάλυση Δεδομένων και Εξαγωγή Επιχειρηματικών Συμπερασμάτων

Η φάση “Analyze” επικεντρώνεται στην ανάλυση και την ερμηνεία των δεδομένων με στόχο την εξαγωγή χρήσιμων πληροφοριών και συμπερασμάτων. Σε αυτό το στάδιο πραγματοποιούνται υπολογισμοί, συγκεντρωτικές αναλύσεις και εντοπισμός προτύπων ή τάσεων στα δεδομένα, ώστε να υποστηριχθεί η διαδικασία λήψης αποφάσεων και η καλύτερη κατανόηση του εξεταζόμενου προβλήματος.

Για το project μας ξεκινάμε με την υλοποίηση των βημάτων που αναφέρονται μέσα στην εκφώνηση:

Follow these steps for using spreadsheets

Open your spreadsheet application, then complete the following steps:

1. Where relevant, make columns consistent and combine them into a single worksheet.
2. Clean and transform your data to prepare for analysis.
3. Conduct descriptive analysis.
4. Run a few calculations in one file to get a better sense of the data layout. Options:
 - Calculate the mean of `ride_length`
 - Calculate the max `ride_length`
 - Calculate the mode of `day_of_week`
5. Create a pivot table to quickly calculate and visualize the data. Options:
 - Calculate the average `ride_length` for members and casual riders. Try rows = `member_casual`; Values = Average of `ride_length`.
 - Calculate the average `ride_length` for users by `day_of_week`. Try columns = `day_of_week`; Rows = `member_casual`; Values = Average of `ride_length`.
 - Calculate the number of rides for users by `day_of_week` by adding Count of `trip_id` to Values.
6. Open another file and perform the same descriptive analysis steps. Explore different seasons to make some initial observations.
7. Once you have spent some time working with the individual spreadsheets, merge them into a full-year view. Do this with the tool you have chosen to use to perform your final analysis, either a spreadsheet, a database and SQL, or Python.
8. Export a summary file for further analysis.

Έχοντας υπολογίσει τις μετρικές του τέταρτου βήματος, αναφέρουμε τα εξής ευρήματα:

- Διαπιστώθηκε ότι η μέση διάρκεια διαδρομής είναι περίπου 11 λεπτά και 28 δευτερόλεπτα, γεγονός που δείχνει ότι οι περισσότερες διαδρομές είναι σχετικά σύντομες και πιθανότατα χρησιμοποιούνται για καθημερινές μετακινήσεις μικρής απόστασης.

- Επιπλέον, η μέγιστη διάρκεια διαδρομής που καταγράφηκε στο τελικό dataset είναι 1 ώρα, καθώς κατά τη φάση επεξεργασίας δεδομένων αφαιρέθηκαν οι ακραίες τιμές που κρίθηκαν μη ρεαλιστικές για τη φύση της υπηρεσίας.
- Τέλος, υπολογίστηκε η επικρατέστερη τιμή του πεδίου day_of_week (mode), η οποία αντιστοιχεί στην ημέρα Τρίτη. Το αποτέλεσμα αυτό δείχνει ότι η συγκεκριμένη ημέρα παρουσιάζει τον μεγαλύτερο αριθμό διαδρομών στο dataset.

Προχωράμε στην δημιουργία pivot tables στα οποία θα αναλύσουμε σωρευτικά τα δεδομένα μας.



Row Label	Average of ride_length
Customer	0:22:12
Subscriber	0:10:49
Grand Total	0:11:28

Average of ride_length	Column Labels							
Row Labels	1	2	3	4	5	6	7	Grand Total
Customer	0:25:35	0:19:39	0:19:29	0:21:43	0:19:40	0:19:26	0:22:57	0:22:12
Subscriber	0:12:08	0:10:37	0:10:44	0:10:42	0:10:36	0:10:26	0:11:28	0:10:49
Grand Total	0:14:34	0:10:55	0:11:03	0:11:08	0:10:55	0:10:48	0:12:47	0:11:28

Count of start_time	Column Label		
Row Labels	Customer	Subscriber	Grand Total
1	13053	59082	72135
2	3809	109235	113044
3	4776	126698	131474
4	4793	120583	125376
5	4475	123783	128258
6	4865	113775	118640
7	7578	58460	66038
Grand Total	43349	711616	754965

Υπενθυμίζεται ότι στο πλαίσιο της παρούσας μελέτης επιλέχθηκε η ανάλυση των δεδομένων του πρώτου τριμήνου (Q1) των ετών 2019 και 2020, δηλαδή της χρονικής περιόδου από τον Ιανουάριο έως και τον Μάρτιο. Παρότι το αρχικό project προτείνει την ανάλυση περισσότερων αρχείων και χρονικών περιόδων με στόχο την εξαγωγή εποχικών συμπερασμάτων, κρίθηκε ότι μια τέτοια προσέγγιση θα απαιτούσε σημαντικά μεγαλύτερο όγκο επεξεργασίας και ανάλυσης δεδομένων, κάτι που ξεπερνά τις ανάγκες και το εύρος της παρούσας capstone εργασίας. Για τον λόγο αυτό θεωρήθηκε επαρκής η επεξεργασία και η ανάλυση των συγκεκριμένων datasets, καθώς μπορούν να προσφέρουν αξιόπιστα συμπεράσματα σχετικά με τη συμπεριφορά των χρηστών και τα πρότυπα χρήσης της υπηρεσίας. Συνεπώς, γίνεται η παραδοχή ότι τα συμπεράσματα που προκύπτουν από την παρούσα ανάλυση αφορούν τη συγκεκριμένη χρονική και εποχική περίοδο κατά την οποία συλλέχθηκαν τα δεδομένα.

Για την βέλτιστη κατανόηση των αποτελεσμάτων της ανάλυσης, αποφασίστηκε να δημιουργηθούν οπτικοποιήσεις δεδομένων από τώρα, ενώ το project ζητάει κάτι τέτοιο στην φάση **Share**.



Η οπτικοποίηση των δεδομένων πραγματοποιήθηκε με στόχο τη διευκόλυνση της κατανόησης των προτύπων χρήσης της υπηρεσίας Cyclistic και την αποτελεσματικότερη σύγκριση της συμπεριφοράς μεταξύ των δύο βασικών κατηγοριών χρηστών, δηλαδή των Customers και των Subscribers. Για τον σκοπό αυτό δημιουργήθηκαν γραφήματα βασισμένα στα αποτελέσματα των pivot tables που προηγήθηκαν, ώστε τα ευρήματα της ανάλυσης να παρουσιαστούν με πιο κατανοητό και άμεσα αξιοποιήσιμο τρόπο.

Αρχικά, χρησιμοποιήθηκε γράφημα γραμμών (Line Chart) για την απεικόνιση της μέσης διάρκειας διαδρομής (Average ride_length) ανά ημέρα της εβδομάδας και ανά κατηγορία χρήστη. Το συγκεκριμένο είδος γραφήματος επιλέχθηκε επειδή είναι ιδιαίτερα κατάλληλο για την παρουσίαση τάσεων και μεταβολών κατά μήκος μίας χρονικής ή διαδοχικής κλίμακας, όπως είναι οι ημέρες της εβδομάδας. Μέσω του γραφήματος παρατηρείται ότι οι Customers πραγματοποιούν σταθερά μεγαλύτερες διαδρομές σε σχέση με τους Subscribers σε όλες τις ημέρες της εβδομάδας. Παράλληλα, διακρίνεται αύξηση της μέσης διάρκειας διαδρομής των Customers κατά το Σαββατοκύριακο και ιδιαίτερα την Κυριακή, γεγονός που υποδηλώνει περισσότερο ψυχαγωγική ή περιστασιακή χρήση της υπηρεσίας. Αντίθετα, οι Subscribers εμφανίζουν αρκετά σταθερή συμπεριφορά και μικρότερες διαδρομές, στοιχείο που ενισχύει την υπόθεση ότι χρησιμοποιούν τα ποδήλατα κυρίως για καθημερινές και πρακτικές μετακινήσεις.

Στη συνέχεια χρησιμοποιήθηκε ομαδοποιημένο ραβδόγραμμα (Clustered Column Chart) για την απεικόνιση του πλήθους διαδρομών ανά ημέρα της εβδομάδας και ανά κατηγορία χρήστη. Το συγκεκριμένο γράφημα επιλέχθηκε επειδή επιτρέπει την άμεση και ξεκάθαρη σύγκριση ποσοτικών δεδομένων μεταξύ διαφορετικών ομάδων. Από το γράφημα προκύπτει ότι οι Subscribers πραγματοποιούν συντριπτικά μεγαλύτερο αριθμό διαδρομών σε σχέση με τους Customers, γεγονός που υποδηλώνει ότι αποτελούν τους κύριους και πιο ενεργούς χρήστες της υπηρεσίας. Επιπλέον, η δραστηριότητα των Subscribers παραμένει σχετικά υψηλή και σταθερή κατά τη διάρκεια των εργάσιμων ημερών, κάτι που συνδέεται με commuting behavior και καθημερινή χρήση της υπηρεσίας ως μέσο μετακίνησης. Από την άλλη πλευρά, οι Customers παρουσιάζουν εμφανή αύξηση στη χρήση της υπηρεσίας κατά το Σαββατοκύριακο και ιδιαίτερα το Σάββατο και την Κυριακή, επιβεβαιώνοντας ότι η συγκεκριμένη κατηγορία χρηστών χρησιμοποιεί συχνότερα την υπηρεσία για leisure-oriented δραστηριότητες και ψυχαγωγικές μετακινήσεις.

Συνολικά, τα αποτελέσματα της ανάλυσης καταδεικνύουν ότι οι δύο κατηγορίες χρηστών εμφανίζουν διαφορετικά πρότυπα χρήσης της υπηρεσίας Cyclistic. Οι Subscribers χρησιμοποιούν την υπηρεσία πιο συχνά αλλά για μικρότερης διάρκειας διαδρομές, γεγονός που παραπέμπει σε καθημερινή πρακτική χρήση, ενώ οι Customers πραγματοποιούν λιγότερες αλλά μεγαλύτερης διάρκειας


διαδρομές, κυρίως κατά το Σαββατοκύριακο, στοιχείο που υποδηλώνει περισσότερο περιστασιακή και ψυχαγωγική χρήση της υπηρεσίας.

Στο πλαίσιο της παρούσας φάσης της ανάλυσης κρίθηκε χρήσιμη η διερεύνηση των δημοφιλέστερων σταθμών εκκίνησης και τερματισμού διαδρομών για τις κατηγορίες χρηστών Subscribers και Customers, με στόχο την καλύτερη κατανόηση των προτύπων μετακίνησης και της συμπεριφοράς χρήσης της υπηρεσίας.


START_STATION CUSTOMER




END_STATION CUSTOMER



START_STATION SUBSCRIBER



END_STATION SUBSCRIBER



Η ανάλυση των δημοφιλέστερων σταθμών εκκίνησης και τερματισμού ανέδειξε σημαντικές διαφοροποιήσεις στα πρότυπα μετακίνησης μεταξύ των Customers και των Subscribers. Για την παρουσίαση των αποτελεσμάτων χρησιμοποιήθηκαν οριζόντια ραβδογράμματα (Horizontal Bar Charts), καθώς το συγκεκριμένο είδος οπτικοποίησης θεωρείται ιδιαίτερα κατάλληλο για τη σύγκριση κατηγοριών με μεγάλα ονόματα μεταβλητών, όπως οι ονομασίες των σταθμών. Επιπλέον, η επιλογή δημιουργίας ξεχωριστών γραφημάτων για κάθε κατηγορία χρήστη κρίθηκε απαραίτητη, λόγω της πολύ μεγάλης διαφοράς στον αριθμό διαδρομών μεταξύ Customers και Subscribers, η οποία καθιστούσε δυσδιάκριτα τα αποτελέσματα όταν οι δύο κατηγορίες εμφανίζονταν στο ίδιο γράφημα.

Από τα αποτελέσματα προκύπτει ότι οι Customers εμφανίζουν έντονη προτίμηση σε σταθμούς που βρίσκονται κοντά σε τουριστικά και ψυχαγωγικά σημεία του Σικάγο (έδρα της εικονικής εταιρείας του project), όπως το Lake Shore Drive, το Millennium Park, το Shedd Aquarium, το Adler Planetarium και το Theater on the Lake. Οι περιοχές αυτές βρίσκονται κατά μήκος της λίμνης Michigan και συνδέονται άμεσα με recreational και tourist-oriented δραστηριότητες της πόλης [4]. Παρατηρείται επίσης ότι αρκετοί από τους δημοφιλέστερους σταθμούς εκκίνησης εμφανίζονται και στους δημοφιλέστερους σταθμούς τερματισμού, γεγονός που υποδηλώνει ότι οι Customers πραγματοποιούν συχνά μικρές κυκλικές ή ψυχαγωγικές διαδρομές στις ίδιες περιοχές της πόλης, κυρίως κοντά στο παραλιακό μέτωπο και σε σημεία αυξημένου τουριστικού ενδιαφέροντος. Η συμπεριφορά αυτή είναι συμβατή με το γεγονός ότι οι Customers χρησιμοποιούν την υπηρεσία περισσότερο περιστασιακά και για leisure activities.

Αντίθετα, οι Subscribers εμφανίζουν διαφορετικό πρότυπο χρήσης. Οι δημοφιλέστεροι σταθμοί τους εντοπίζονται κυρίως σε περιοχές του κέντρου του Σικάγο και κοντά σε επιχειρηματικά και εμπορικά σημεία της πόλης, όπως οι περιοχές Clinton Street, Canal Street, Columbus Drive και Kinzie Street. Οι περιοχές αυτές συνδέονται με το downtown Chicago και με σημαντικούς κόμβους καθημερινής μετακίνησης και εργασίας [5]. Επιπλέον, παρατηρείται ότι οι Subscribers παρουσιάζουν πολύ μεγαλύτερη συγκέντρωση διαδρομών σε συγκεκριμένους σταθμούς, γεγονός που ενισχύει την υπόθεση ότι χρησιμοποιούν την υπηρεσία ως μέσο καθημερινής μετακίνησης (commuting). Η επαναλαμβανόμενη χρήση συγκεκριμένων σταθμών εκκίνησης και τερματισμού υποδηλώνει πιο σταθερά και προβλέψιμα πρότυπα μετακίνησης σε σχέση με τους Customers.

Συνολικά, η ανάλυση των σταθμών εκκίνησης και τερματισμού **επιβεβαιώνει τα συμπεράσματα που προέκυψαν και από τις προηγούμενες αναλύσεις** σχετικά με τα διαφορετικά πρότυπα χρήσης της υπηρεσίας μεταξύ Customers και Subscribers. Οι Customers φαίνεται να κινούνται κυρίως σε περιοχές του παραλιακού μετώπου του Σικάγο και κοντά σε σημεία αυξημένου τουριστικού και ψυχαγωγικού ενδιαφέροντος, όπως το Millennium Park, το Shedd Aquarium και η περιοχή της Lake Shore Drive, γεγονός που υποδηλώνει περισσότερο leisure-oriented και περιστασιακή χρήση της υπηρεσίας. Αντίθετα, οι Subscribers εμφανίζουν μεγαλύτερη δραστηριότητα σε σταθμούς που βρίσκονται κυρίως στο κέντρο του Σικάγο και σε περιοχές με έντονη καθημερινή κινητικότητα, στοιχείο που ενισχύει την υπόθεση ότι χρησιμοποιούν το σύστημα ποδηλάτων κυρίως ως μέσο καθημερινής μετακίνησης και commuting μέσα στον αστικό ιστό της πόλης.

6. Share Phase – Οπτικοποίηση Δεδομένων και Παρουσίαση Ευρημάτων

Η φάση “Share” επικεντρώνεται στην παρουσίαση των αποτελεσμάτων της ανάλυσης με τρόπο κατανοητό, οργανωμένο και εύκολα αξιοποιήσιμο από το κοινό στο οποίο απευθύνεται η μελέτη. Σε αυτή τη φάση, τα δεδομένα και τα συμπεράσματα που προέκυψαν από την ανάλυση μετατρέπονται σε οπτικοποιήσεις, dashboards και παρουσιάσεις, με στόχο την αποτελεσματική επικοινωνία των βασικών ευρημάτων και των επιχειρηματικών συμπερασμάτων.

Σε ένα πραγματικό επιχειρηματικό περιβάλλον, στο σημείο αυτό θα ακολουθούσε συνήθως η δημιουργία μίας ολοκληρωμένης παρουσίασης ή dashboard μέσω εργαλείων όπως PowerPoint, Google Slides ή Tableau, με στόχο την παρουσίαση των ευρημάτων προς stakeholders ή διοικητικά στελέχη. Ωστόσο, η διαδικασία αυτή κρίθηκε ότι θα απαιτούσε σημαντικό επιπλέον χρόνο και κόπο χωρίς να προσφέρει ουσιαστική επιπλέον αξία στα πλαίσια της παρούσας εκπαιδευτικής εργασίας.

Υπενθυμίζεται για το παρόν project ότι τα απαραίτητα γραφήματα, οι οπτικοποιήσεις και τα βασικά συμπεράσματα έχουν ήδη παραχθεί και παρουσιαστεί αναλυτικά στην φάση “Analyze”.

7. Act Phase – Τελικά Συμπεράσματα και Επιχειρηματικές Προτάσεις

Η φάση “Act” αποτελεί το τελικό στάδιο της διαδικασίας ανάλυσης δεδομένων και επικεντρώνεται στην αξιοποίηση των συμπερασμάτων που προέκυψαν από την ανάλυση, με στόχο τη διαμόρφωση προτάσεων και πιθανών επιχειρηματικών ενεργειών. Σε αυτή τη φάση πραγματοποιείται η σύνθεση των βασικών ευρημάτων της μελέτης και εξετάζεται με ποιον τρόπο τα αποτελέσματα μπορούν να αξιοποιηθούν για τη λήψη αποφάσεων και τη βελτίωση της λειτουργίας ή της στρατηγικής μίας επιχείρησης.

Με βάση τα αποτελέσματα της παρούσας ανάλυσης, διαπιστώθηκε ότι οι Subscribers χρησιμοποιούν την υπηρεσία ποδηλάτων κυρίως ως μέσο καθημερινής μετακίνησης, παρουσιάζοντας υψηλή και σταθερή δραστηριότητα κατά τις εργάσιμες ημέρες και σε σταθμούς που βρίσκονται κυρίως στο κέντρο του Σικάγο και κοντά σε επιχειρηματικές περιοχές. Αντίθετα, οι Customers εμφανίζουν περισσότερο leisure-oriented πρότυπο χρήσης, πραγματοποιώντας μεγαλύτερης διάρκειας διαδρομές κυρίως κατά το Σαββατοκύριακο και σε περιοχές με αυξημένο τουριστικό και ψυχαγωγικό ενδιαφέρον κοντά στη λίμνη Michigan και το παραλιακό μέτωπο της πόλης.

Με βάση τα παραπάνω ευρήματα, και λαμβάνοντας υπόψη ότι βασικός επιχειρηματικός στόχος της Cyclistic αποτελεί η μετατροπή περισσότερων Customers σε Subscribers, διαμορφώνονται οι ακόλουθες προτεινόμενες στρατηγικές και επιχειρηματικές ενέργειες:

1. Δημιουργία ειδικών promotional membership campaigns για Customers με υψηλή δραστηριότητα.

Η ανάλυση έδειξε ότι αρκετοί Customers χρησιμοποιούν συχνά την υπηρεσία και πραγματοποιούν σχετικά μεγάλες διαδρομές, ιδιαίτερα κατά το Σαββατοκύριακο. Η Cyclistic θα μπορούσε να αξιοποιήσει αυτή τη συμπεριφορά προσφέροντας προσωποποιημένες προσφορές, δωρεάν δοκιμαστικές συνδρομές ή εκπτώσεις σε monthly memberships προς χρήστες που εμφανίζουν επαναλαμβανόμενη χρήση της υπηρεσίας. Με τον τρόπο αυτό αυξάνονται οι πιθανότητες μετατροπής περιστασιακών χρηστών σε μόνιμους Subscribers.

2. Ανάπτυξη leisure-oriented subscription packages για τουριστική και ψυχαγωγική χρήση.

Δεδομένου ότι οι Customers χρησιμοποιούν κυρίως σταθμούς κοντά σε τουριστικές και recreational περιοχές του Σικάγο, η εταιρεία θα μπορούσε να δημιουργήσει ειδικά συνδρομητικά πακέτα προσαρμοσμένα σε αυτού του είδους τη χρήση. Για παράδειγμα, θα μπορούσαν να προσφερθούν

weekend memberships, tourist subscriptions ή seasonal passes που να στοχεύουν χρήστες οι οποίοι χρησιμοποιούν συχνά την υπηρεσία για βόλτες και ψυχαγωγικές δραστηριότητες. Η στρατηγική αυτή θα μπορούσε να λειτουργήσει ως ενδιάμεσο στάδιο πριν από τη μετάβαση σε πλήρη συνδρομή.

3. **Ενίσχυση της εμπειρίας χρήσης σε σταθμούς υψηλής δημοτικότητας.**

Η ανάλυση των δημοφιλέστερων σταθμών έδειξε ότι συγκεκριμένες περιοχές συγκεντρώνουν μεγάλο όγκο διαδρομών τόσο από Customers όσο και από Subscribers. Η Cyclistic θα μπορούσε να βελτιώσει τη διαθεσιμότητα ποδηλάτων και τη συνολική εμπειρία χρήσης στους σταθμούς αυτούς, μειώνοντας προβλήματα έλλειψης διαθέσιμων ποδηλάτων ή θέσεων στάθμευσης. Μία πιο αξιόπιστη και ομαλή εμπειρία χρήσης μπορεί να αυξήσει την ικανοποίηση των Customers και να ενισχύσει τη διάθεσή τους να επενδύσουν σε μία μακροχρόνια συνδρομή.

Συνολικά, τα αποτελέσματα της ανάλυσης υποδεικνύουν ότι η Cyclistic μπορεί να αξιοποιήσει τις διαφορές στη συμπεριφορά μεταξύ Customers και Subscribers ώστε να αναπτύξει πιο στοχευμένες στρατηγικές marketing και υπηρεσίες, με τελικό στόχο την αύξηση των συνδρομητών.

8. Σύνοψη Έργου

Η παρούσα εργασία υλοποιήθηκε στο πλαίσιο του προγράμματος “Google Data Analytics Professional Certificate” [1] και αποτελεί το τελικό capstone project του προγράμματος πιστοποίησης. Στόχος του έργου ήταν η εφαρμογή στην πράξη των βασικών αρχών, τεχνικών και διαδικασιών της ανάλυσης δεδομένων μέσα από μία ολοκληρωμένη μελέτη περίπτωσης πραγματικού επιχειρηματικού χαρακτήρα.

Μέσα από το συγκεκριμένο project παρουσιάστηκαν και εφαρμόστηκαν όλα τα βασικά στάδια του κύκλου ζωής της ανάλυσης δεδομένων, ακολουθώντας τη μεθοδολογία Ask, Prepare, Process, Analyze, Share και Act που προτείνεται από το πρόγραμμα του Google Data Analytics Certificate. Η διαδικασία ξεκίνησε με τον καθορισμό του επιχειρηματικού προβλήματος και των βασικών ερευνητικών ερωτημάτων, συνεχίστηκε με τη συλλογή, προετοιμασία και επεξεργασία των δεδομένων, ενώ στη συνέχεια πραγματοποιήθηκε ανάλυση και οπτικοποίηση των δεδομένων με στόχο την εξαγωγή χρήσιμων πληροφοριών και επιχειρηματικών συμπερασμάτων. Τέλος, πραγματοποιήθηκε η παρουσίαση των αποτελεσμάτων * και η διαμόρφωση προτεινόμενων επιχειρηματικών ενεργειών και στρατηγικών, βασισμένων στα ευρήματα της ανάλυσης.

Στο πλαίσιο της εργασίας χρησιμοποιήθηκαν εργαλεία και τεχνικές που αξιοποιούνται ευρέως στον χώρο της ανάλυσης δεδομένων, όπως υπολογιστικά φύλλα Excel/Google Sheets, pivot tables, data visualizations και διαδικασίες καθαρισμού και μετασχηματισμού δεδομένων. Παράλληλα, δόθηκε ιδιαίτερη έμφαση στην ποιότητα και αξιοπιστία των δεδομένων, καθώς και στη σωστή ερμηνεία και παρουσίαση των αποτελεσμάτων.

Η παρούσα μελέτη αποτελεί ένα ολοκληρωμένο παράδειγμα εφαρμογής της επιστήμης δεδομένων και της διαδικασίας data analysis σε πραγματικό επιχειρηματικό σενάριο, αναδεικνύοντας τη σημασία της ανάλυσης δεδομένων στη διαδικασία λήψης αποφάσεων και στη διαμόρφωση στρατηγικών βασισμένων σε δεδομένα (data-driven decision making). Μέσα από το έργο αυτό αναδείχθηκε η αξία της σωστής προετοιμασίας, ανάλυσης και οπτικοποίησης δεδομένων, καθώς και ο ρόλος που μπορεί να διαδραματίσει η ανάλυση δεδομένων στη βελτίωση υπηρεσιών, στη βαθύτερη κατανόηση της συμπεριφοράς χρηστών και στη γενικότερη υποστήριξη επιχειρηματικών αποφάσεων.

* Όπως αναφέρεται και στο τμήμα του “Share Phase”, η διαδικασία παρουσίασης και οπτικοποίησης των αποτελεσμάτων ενσωματώθηκε ουσιαστικά στο στάδιο του “Analyze Phase”, για τους λόγους που αναλύθηκαν στη συγκεκριμένη ενότητα.

Βιβλιογραφία / Αναφορές

1. <https://www.coursera.org/professional-certificates/google-data-analytics>, Η σελίδα του “Google Data Analytics Professional Certificate”.
2. <https://divvy-tripdata.s3.amazonaws.com/index.html>, Index of bucket "divvy-tripdata".
3. <https://docs.google.com/spreadsheets/d/1ipoS7iL05kyRn8if2xXXotAmxtnaZgezjxxJe8R4Yt4>, Το αρχείο “Divvy_Trips_final”.
4. https://en.wikipedia.org/wiki/Lake_Shore_Drive, Πληροφορίες για την λεωφόρο “Lake Shore Drive” του Σικάγο.
5. https://en.wikipedia.org/wiki/Chicago_Loop, Πληροφορίες για το κέντρο του Σικάγο.