

**Ανάλυση Δεδομένων επί Συστήματος Κοινόχρηστων Ποδηλάτων:
Μετατροπή Περιστασιακών Χρηστών σε Ετήσιους Συνδρομητές**



Νικόλαος Μπελιμπασάκης
Μηχανικός Η/Υ και Πληροφορικής

Πίνακας Περιεχομένων

1. Εισαγωγή και Παρουσίαση του Έργου	2
2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος	4
3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων	5
4. Εργαλεία και Τεχνολογίες που Χρησιμοποιήθηκαν	
5. Εξερευνητική Ανάλυση Δεδομένων (EDA)	
6. Οπτικοποίηση Δεδομένων και Dashboard	
7. Βασικά Ευρήματα και Συμπεράσματα	
8. Προτεινόμενες Στρατηγικές και Προτάσεις	
9. Συμπεράσματα	
10. Βιβλιογραφία / Αναφορές	

1. Εισαγωγή και Παρουσίαση του Έργου

Η Cyclistic αποτελεί μία υποθετική εταιρεία παροχής υπηρεσιών κοινόχρηστων ποδηλάτων με έδρα το Σικάγο των Ηνωμένων Πολιτειών, όπως περιγράφεται στη μελέτη περίπτωσης (case study) του Google Data Analytics Professional Certificate. Η εταιρεία διαθέτει περισσότερα από 5.800 ποδήλατα και περισσότερους από 600 σταθμούς στάθμευσης, επιτρέποντας στους χρήστες να παραλαμβάνουν και να επιστρέφουν ποδήλατα σε διαφορετικά σημεία της πόλης. Επιπλέον, η Cyclistic προσφέρει διαφορετικούς τύπους ποδηλάτων, όπως κλασικά ποδήλατα, ανακλινόμενα ποδήλατα, χειροκίνητα τρίκυκλα και ποδήλατα μεταφοράς φορτίου, με στόχο την ενίσχυση της προσβασιμότητας και την εξυπηρέτηση διαφορετικών κατηγοριών χρηστών.

Η πλειονότητα των χρηστών επιλέγει τα παραδοσιακά ποδήλατα, ενώ ένα μικρό ποσοστό χρησιμοποιεί τις ειδικές υποστηρικτικές επιλογές. Παράλληλα, σημαντικό μέρος των χρηστών χρησιμοποιεί τις υπηρεσίες της εταιρείας είτε για ψυχαγωγικούς σκοπούς είτε για καθημερινή μετακίνηση προς την εργασία. Η εταιρεία βασίζεται σε ένα ευέλικτο σύστημα συνδρομών, το οποίο περιλαμβάνει μεμονωμένες διαδρομές, ημερήσια πάσα και ετήσιες συνδρομές. Οι χρήστες που χρησιμοποιούν μεμονωμένες ή ημερήσιες διαδρομές χαρακτηρίζονται ως περιστασιακοί χρήστες (casual riders), ενώ οι χρήστες που διαθέτουν ετήσια συνδρομή χαρακτηρίζονται ως μέλη (annual members).

Σύμφωνα με τα επιχειρηματικά δεδομένα της υποθετικής εταιρείας, οι ετήσιοι συνδρομητές αποφέρουν σημαντικά μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες. Για τον λόγο αυτό, η Cyclistic επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, αναπτύσσοντας νέες στρατηγικές marketing που θα στοχεύουν στη μετατροπή περιστασιακών χρηστών σε μόνιμα μέλη της υπηρεσίας.

Σημαντικό ρόλο στη διαδικασία αυτή διαδραματίζει η Lily Moreno, η οποία αποτελεί τη διευθύντρια marketing της Cyclistic και υπεύθυνη για την ανάπτυξη διαφημιστικών καμπανιών και στρατηγικών προώθησης της υπηρεσίας. Η Moreno πιστεύει ότι η μελλοντική ανάπτυξη της εταιρείας εξαρτάται από τη μεγιστοποίηση των ετήσιων συνδρομών και θεωρεί ότι οι υπάρχοντες περιστασιακοί χρήστες αποτελούν την καλύτερη ευκαιρία για μελλοντική ανάπτυξη, καθώς είναι ήδη εξοικειωμένοι με τις υπηρεσίες της Cyclistic.

Παράλληλα, η ομάδα marketing analytics της εταιρείας είναι υπεύθυνη για τη συλλογή, ανάλυση και παρουσίαση δεδομένων που συμβάλλουν στη λήψη επιχειρηματικών αποφάσεων και στη διαμόρφωση στρατηγικών marketing. Στο πλαίσιο της μελέτης περίπτωσης, ο ρόλος του αναλυτή δεδομένων είναι η

επεξεργασία και ανάλυση των ιστορικών δεδομένων διαδρομών, με σκοπό την εξαγωγή χρήσιμων συμπερασμάτων σχετικά με τις διαφορές στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Επιπλέον, η διοικητική ομάδα της Cyclistic είναι υπεύθυνη για την αξιολόγηση των αποτελεσμάτων της ανάλυσης και την έγκριση των προτεινόμενων στρατηγικών marketing.

Το παρόν έργο αποτελεί μία ολοκληρωμένη μελέτη ανάλυσης δεδομένων, η οποία υλοποιείται στα πλαίσια του Google Data Analytics Professional Certificate. Κύριος στόχος του έργου είναι η ανάλυση ιστορικών δεδομένων διαδρομών της Cyclistic, με σκοπό την κατανόηση των διαφορών στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Μέσα από τις διαδικασίες συλλογής, καθαρισμού, επεξεργασίας, ανάλυσης και οπτικοποίησης δεδομένων, επιδιώκεται η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που μπορούν να συμβάλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος

Η φάση “Ask” αποτελεί το πρώτο στάδιο της διαδικασίας ανάλυσης δεδομένων και επικεντρώνεται στον καθορισμό του επιχειρηματικού προβλήματος, των βασικών στόχων της ανάλυσης και των ερευνητικών ερωτημάτων που θα καθοδηγήσουν τη μελέτη. Στην παρούσα μελέτη περίπτωσης, η Cyclistic επιδιώκει να κατανοήσει καλύτερα τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων, με στόχο την ανάπτυξη αποτελεσματικότερων στρατηγικών marketing.

Σύμφωνα με τα επιχειρηματικά δεδομένα της εταιρείας, οι ετήσιοι συνδρομητές (annual members) αποφέρουν μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες (casual riders). Για τον λόγο αυτό, η εταιρεία επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, μετατρέποντας όσο το δυνατόν περισσότερους περιστασιακούς χρήστες σε μόνιμα μέλη της υπηρεσίας.

Για την επίτευξη του παραπάνω στόχου, η ομάδα marketing της Cyclistic διατύπωσε τρία βασικά ερευνητικά ερωτήματα, τα οποία θα καθοδηγήσουν τη μελλοντική στρατηγική marketing της εταιρείας:

1. Πώς χρησιμοποιούν διαφορετικά τα ποδήλατα της Cyclistic οι ετήσιοι συνδρομητές και οι περιστασιακοί χρήστες;
2. Γιατί οι περιστασιακοί χρήστες θα επέλεγαν μία ετήσια συνδρομή;
3. Πώς μπορεί η Cyclistic να αξιοποιήσει τα ψηφιακά μέσα (digital media) ώστε να επηρεάσει τους περιστασιακούς χρήστες και να τους μετατρέψει σε ετήσιους συνδρομητές;

Στα πλαίσια της παρούσας μελέτης, η ανάλυση επικεντρώνεται κυρίως στο πρώτο ερευνητικό ερώτημα, δηλαδή στην κατανόηση των διαφορών στη συμπεριφορά μεταξύ ετήσιων συνδρομητών και περιστασιακών χρηστών. Μέσα από την ανάλυση ιστορικών δεδομένων διαδρομών, επιδιώκεται η αναγνώριση προτύπων χρήσης, τάσεων και διαφορών στις συνήθειες των δύο κατηγοριών χρηστών.

Οι βασικοί stakeholders της μελέτης είναι η Lily Moreno, διευθύντρια marketing της Cyclistic, η ομάδα marketing analytics της εταιρείας, καθώς και η διοικητική ομάδα της Cyclistic, η οποία θα αξιολογήσει τα αποτελέσματα της ανάλυσης και τις προτεινόμενες στρατηγικές marketing.

Τέλος, βασικός στόχος της ανάλυσης είναι η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που θα μπορούσαν να συμβάλλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων

Η φάση “Prepare” επικεντρώνεται στη συλλογή, οργάνωση και προετοιμασία των δεδομένων που θα χρησιμοποιηθούν για την ανάλυση. Στην παρούσα μελέτη χρησιμοποιήθηκαν τα ιστορικά δεδομένα διαδρομών της Cyclistic [1], τα οποία παρέχονται στα πλαίσια του case study του Google Data Analytics Professional Certificate. Τα δεδομένα αυτά είναι δημόσια διαθέσιμα και περιλαμβάνουν πληροφορίες σχετικά με τις διαδρομές των χρηστών του συστήματος κοινόχρηστων ποδηλάτων.

Τα datasets περιέχουν πληροφορίες όπως το μοναδικό αναγνωριστικό κάθε διαδρομής (trip_id), τον χρόνο έναρξης και λήξης της διαδρομής, τη διάρκεια της διαδρομής, τους σταθμούς εκκίνησης και τερματισμού, τον τύπο χρήστη (casual rider ή annual member), καθώς και πρόσθετα στοιχεία σχετικά με τα ποδήλατα και τις διαδρομές. Τα δεδομένα οργανώνονται σε μορφή πινάκων CSV, γεγονός που επιτρέπει την εύκολη επεξεργασία και ανάλυσή τους με εργαλεία όπως Python, pandas και SQL.

Για τις ανάγκες της ανάλυσης, τα δεδομένα λήφθηκαν και αποθηκεύτηκαν σε κατάλληλη δομή φακέλων. Παράλληλα, εξετάστηκαν ζητήματα που σχετίζονται με την ακεραιότητα, την αξιοπιστία και την ιδιωτικότητα των δεδομένων. Σύμφωνα με την περιγραφή του case study, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που διασφαλίζει την προστασία προσωπικών δεδομένων και τη συμμόρφωση με τις πολιτικές απορρήτου.

Κατά τη φάση προετοιμασίας πραγματοποιήθηκε αρχικός έλεγχος της ακεραιότητας και της ποιότητας των δεδομένων. Μέσα από την προκαταρκτική διερεύνηση εντοπίστηκαν ορισμένες ελλειπίες τιμές (missing values), καθώς και πιθανά ασυνεπή ή μη έγκυρα δεδομένα σε συγκεκριμένα πεδία. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν αναλυτικότερα στη φάση επεξεργασίας και καθαρισμού των δεδομένων (Process Phase), με στόχο τη διασφάλιση της αξιοπιστίας της ανάλυσης.

Τα ιστορικά δεδομένα διαδρομών της Cyclistic παρέχουν πολύτιμες πληροφορίες σχετικά με τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων. Μέσα από δεδομένα όπως η διάρκεια διαδρομών, οι ώρες και ημέρες χρήσης, οι σταθμοί εκκίνησης και τερματισμού, καθώς και ο τύπος χρήστη, καθίσταται δυνατή η αναγνώριση διαφορών μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Η ανάλυση αυτών των προτύπων χρήσης συμβάλλει στην καλύτερη κατανόηση των συνηθειών των χρηστών και υποστηρίζει τη διαμόρφωση αποτελεσματικότερων στρατηγικών marketing για την αύξηση των ετήσιων συνδρομών.

Κατά την αρχική διερεύνηση των δεδομένων εντοπίστηκαν ορισμένα ζητήματα που θα μπορούσαν να επηρεάσουν την ανάλυση. Συγκεκριμένα, παρατηρήθηκαν ελλιπείς τιμές (missing values) σε ορισμένα πεδία, καθώς και πιθανές ασυνέπειες ή μη έγκυρες εγγραφές σε δεδομένα διαδρομών. Επιπλέον, λόγω περιορισμών που σχετίζονται με την προστασία προσωπικών δεδομένων, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που περιορίζει τη δυνατότητα βαθύτερης ανάλυσης της συμπεριφοράς των πελατών. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν κατά τις επόμενες φάσεις καθαρισμού και επεξεργασίας των δεδομένων.

Παρατίθεται ένα απόσπασμα από το αρχείο “Divvy_Trips_2019_Q1”:

trip_id	start_time	end_time	bikeid	tripduration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	gender	birthyear
21742443	2019-01-01 0:04:37	2019-01-01 0:11	2167	390	199	Wabash Ave & C	84	Milwaukee Ave & S	Subscriber	Male	1989
21742444	2019-01-01 0:08:13	2019-01-01 0:15	4386	441	44	State St & Rand	624	Dearborn St & V	Subscriber	Female	1990
21742445	2019-01-01 0:13:23	2019-01-01 0:27	1524	829	15	Racine Ave & 18	644	Western Ave & F	Subscriber	Female	1994
21742446	2019-01-01 0:13:45	2019-01-01 0:43	252	1,783.00	123	California Ave &	176	Clark St & Elm S	Subscriber	Male	1993
21742447	2019-01-01 0:14:52	2019-01-01 0:20	1170	364	173	Mies van der Ro	35	Streeter Dr & Gr	Subscriber	Male	1994
21742448	2019-01-01 0:15:33	2019-01-01 0:19	2437	216	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Female	1983
21742449	2019-01-01 0:16:06	2019-01-01 0:19	2708	177	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Male	1984
21742450	2019-01-01 0:18:41	2019-01-01 0:20	2796	100	211	St. Clair St & Eri	142	McClurg Ct & Er	Subscriber	Male	1990
21742451	2019-01-01 0:18:43	2019-01-01 0:47	6205	1,727.00	150	Fort Dearborn D	148	State St & 33rd S	Subscriber	Male	1995
21742452	2019-01-01 0:19:18	2019-01-01 0:24	3939	336	268	Lake Shore Dr &	141	Clark St & Lincol	Subscriber	Male	1996
21742453	2019-01-01 0:20:34	2019-01-01 0:35	6243	886	299	Halsted St & Ro	295	Broadway & Arg	Subscriber	Male	1994
21742454	2019-01-01 0:21:52	2019-01-01 0:32	6300	653	204	Prairie Ave & Ga	420	Ellis Ave & 55th	Subscriber	Female	1994
21742455	2019-01-01 0:23:04	2019-01-01 0:33	3029	601	90	Millennium Park	255	Indiana Ave & R	Subscriber	Male	1986
21742456	2019-01-01 0:23:43	2019-01-01 0:33	84	562	90	Millennium Park	255	Indiana Ave & R	Customer	Female	1990
21742457	2019-01-01 0:23:54	2019-01-01 0:39	5019	906	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742458	2019-01-01 0:24:08	2019-01-01 0:39	5526	892	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742459	2019-01-01 0:24:13	2019-01-01 0:31	3373	407	152	Lincoln Ave & Di	166	Ashland Ave & V	Subscriber	Male	1967
21742460	2019-01-01 0:24:27	2019-01-01 0:47	5777	1,356.00	268	Lake Shore Dr &	319	Greenview Ave &	Customer	Female	1990
21742461	2019-01-01 0:25:28	2019-01-01 0:27	3940	102	35	Streeter Dr & Gr	35	Streeter Dr & Gr	Subscriber	Male	1985
21742463	2019-01-01 0:29:19	2019-01-01 1:08	3914	2,333.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742464	2019-01-01 0:29:21	2019-01-01 0:45	140	960	47	State St & Kinzie	111	Sedgwick St & H	Subscriber	Male	1957
21742465	2019-01-01 0:29:28	2019-01-01 1:07	3355	2,301.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742466	2019-01-01 0:29:47	2019-01-01 0:49	5026	1,168.00	85	Michigan Ave &	329	Lake Shore Dr &	Subscriber	Male	1959

Βιβλιογραφία / Αναφορές

1. <https://divvy-tripdata.s3.amazonaws.com/index.html>, “Index of bucket "divvy-tripdata"”.