

**Ανάλυση Δεδομένων επί Συστήματος Κοινόχρηστων Ποδηλάτων:
Μετατροπή Περιστασιακών Χρηστών σε Ετήσιους Συνδρομητές**



Νικόλαος Μπελιμπασάκης
Μηχανικός Η/Υ και Πληροφορικής

Πίνακας Περιεχομένων

1. Εισαγωγή και Παρουσίαση του Έργου	2
2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος	4
3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων	5
4. Process Phase – Καθαρισμός και Επεξεργασία Δεδομένων	6
5. Εξερευνητική Ανάλυση Δεδομένων (EDA)	
6. Οπτικοποίηση Δεδομένων και Dashboard	
7. Βασικά Ευρήματα και Συμπεράσματα	
8. Προτεινόμενες Στρατηγικές και Προτάσεις	
9. Συμπεράσματα	
10. Βιβλιογραφία / Αναφορές	

1. Εισαγωγή και Παρουσίαση του Έργου

Η Cyclistic αποτελεί μία υποθετική εταιρεία παροχής υπηρεσιών κοινόχρηστων ποδηλάτων με έδρα το Σικάγο των Ηνωμένων Πολιτειών, όπως περιγράφεται στη μελέτη περίπτωσης (case study) του Google Data Analytics Professional Certificate. Η εταιρεία διαθέτει περισσότερα από 5.800 ποδήλατα και περισσότερους από 600 σταθμούς στάθμευσης, επιτρέποντας στους χρήστες να παραλαμβάνουν και να επιστρέφουν ποδήλατα σε διαφορετικά σημεία της πόλης. Επιπλέον, η Cyclistic προσφέρει διαφορετικούς τύπους ποδηλάτων, όπως κλασικά ποδήλατα, ανακλινόμενα ποδήλατα, χειροκίνητα τρίκυκλα και ποδήλατα μεταφοράς φορτίου, με στόχο την ενίσχυση της προσβασιμότητας και την εξυπηρέτηση διαφορετικών κατηγοριών χρηστών.

Η πλειονότητα των χρηστών επιλέγει τα παραδοσιακά ποδήλατα, ενώ ένα μικρό ποσοστό χρησιμοποιεί τις ειδικές υποστηρικτικές επιλογές. Παράλληλα, σημαντικό μέρος των χρηστών χρησιμοποιεί τις υπηρεσίες της εταιρείας είτε για ψυχαγωγικούς σκοπούς είτε για καθημερινή μετακίνηση προς την εργασία. Η εταιρεία βασίζεται σε ένα ευέλικτο σύστημα συνδρομών, το οποίο περιλαμβάνει μεμονωμένες διαδρομές, ημερήσια πάσα και ετήσιες συνδρομές. Οι χρήστες που χρησιμοποιούν μεμονωμένες ή ημερήσιες διαδρομές χαρακτηρίζονται ως περιστασιακοί χρήστες (casual riders), ενώ οι χρήστες που διαθέτουν ετήσια συνδρομή χαρακτηρίζονται ως μέλη (annual members).

Σύμφωνα με τα επιχειρηματικά δεδομένα της υποθετικής εταιρείας, οι ετήσιοι συνδρομητές αποφέρουν σημαντικά μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες. Για τον λόγο αυτό, η Cyclistic επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, αναπτύσσοντας νέες στρατηγικές marketing που θα στοχεύουν στη μετατροπή περιστασιακών χρηστών σε μόνιμα μέλη της υπηρεσίας.

Σημαντικό ρόλο στη διαδικασία αυτή διαδραματίζει η Lily Moreno, η οποία αποτελεί τη διευθύντρια marketing της Cyclistic και υπεύθυνη για την ανάπτυξη διαφημιστικών καμπανιών και στρατηγικών προώθησης της υπηρεσίας. Η Moreno πιστεύει ότι η μελλοντική ανάπτυξη της εταιρείας εξαρτάται από τη μεγιστοποίηση των ετήσιων συνδρομών και θεωρεί ότι οι υπάρχοντες περιστασιακοί χρήστες αποτελούν την καλύτερη ευκαιρία για μελλοντική ανάπτυξη, καθώς είναι ήδη εξοικειωμένοι με τις υπηρεσίες της Cyclistic.

Παράλληλα, η ομάδα marketing analytics της εταιρείας είναι υπεύθυνη για τη συλλογή, ανάλυση και παρουσίαση δεδομένων που συμβάλλουν στη λήψη επιχειρηματικών αποφάσεων και στη διαμόρφωση στρατηγικών marketing. Στο πλαίσιο της μελέτης περίπτωσης, ο ρόλος του αναλυτή δεδομένων είναι η

επεξεργασία και ανάλυση των ιστορικών δεδομένων διαδρομών, με σκοπό την εξαγωγή χρήσιμων συμπερασμάτων σχετικά με τις διαφορές στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Επιπλέον, η διοικητική ομάδα της Cyclistic είναι υπεύθυνη για την αξιολόγηση των αποτελεσμάτων της ανάλυσης και την έγκριση των προτεινόμενων στρατηγικών marketing.

Το παρόν έργο αποτελεί μία ολοκληρωμένη μελέτη ανάλυσης δεδομένων, η οποία υλοποιείται στα πλαίσια του Google Data Analytics Professional Certificate. Κύριος στόχος του έργου είναι η ανάλυση ιστορικών δεδομένων διαδρομών της Cyclistic, με σκοπό την κατανόηση των διαφορών στη συμπεριφορά μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Μέσα από τις διαδικασίες συλλογής, καθαρισμού, επεξεργασίας, ανάλυσης και οπτικοποίησης δεδομένων, επιδιώκεται η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που μπορούν να συμβάλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

2. Ask Phase – Καθορισμός του Επιχειρηματικού Προβλήματος

Η φάση “Ask” αποτελεί το πρώτο στάδιο της διαδικασίας ανάλυσης δεδομένων και επικεντρώνεται στον καθορισμό του επιχειρηματικού προβλήματος, των βασικών στόχων της ανάλυσης και των ερευνητικών ερωτημάτων που θα καθοδηγήσουν τη μελέτη. Στην παρούσα μελέτη περίπτωσης, η Cyclistic επιδιώκει να κατανοήσει καλύτερα τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων, με στόχο την ανάπτυξη αποτελεσματικότερων στρατηγικών marketing.

Σύμφωνα με τα επιχειρηματικά δεδομένα της εταιρείας, οι ετήσιοι συνδρομητές (annual members) αποφέρουν μεγαλύτερη κερδοφορία σε σχέση με τους περιστασιακούς χρήστες (casual riders). Για τον λόγο αυτό, η εταιρεία επιδιώκει να αυξήσει τον αριθμό των ετήσιων συνδρομών, μετατρέποντας όσο το δυνατόν περισσότερους περιστασιακούς χρήστες σε μόνιμα μέλη της υπηρεσίας.

Για την επίτευξη του παραπάνω στόχου, η ομάδα marketing της Cyclistic διατύπωσε τρία βασικά ερευνητικά ερωτήματα, τα οποία θα καθοδηγήσουν τη μελλοντική στρατηγική marketing της εταιρείας:

1. Πώς χρησιμοποιούν διαφορετικά τα ποδήλατα της Cyclistic οι ετήσιοι συνδρομητές και οι περιστασιακοί χρήστες;
2. Γιατί οι περιστασιακοί χρήστες θα επέλεγαν μία ετήσια συνδρομή;
3. Πώς μπορεί η Cyclistic να αξιοποιήσει τα ψηφιακά μέσα (digital media) ώστε να επηρεάσει τους περιστασιακούς χρήστες και να τους μετατρέψει σε ετήσιους συνδρομητές;

Στα πλαίσια της παρούσας μελέτης, η ανάλυση επικεντρώνεται κυρίως στο πρώτο ερευνητικό ερώτημα, δηλαδή στην κατανόηση των διαφορών στη συμπεριφορά μεταξύ ετήσιων συνδρομητών και περιστασιακών χρηστών. Μέσα από την ανάλυση ιστορικών δεδομένων διαδρομών, επιδιώκεται η αναγνώριση προτύπων χρήσης, τάσεων και διαφορών στις συνήθειες των δύο κατηγοριών χρηστών.

Οι βασικοί stakeholders της μελέτης είναι η Lily Moreno, διευθύντρια marketing της Cyclistic, η ομάδα marketing analytics της εταιρείας, καθώς και η διοικητική ομάδα της Cyclistic, η οποία θα αξιολογήσει τα αποτελέσματα της ανάλυσης και τις προτεινόμενες στρατηγικές marketing.

Τέλος, βασικός στόχος της ανάλυσης είναι η εξαγωγή χρήσιμων επιχειρηματικών συμπερασμάτων και η διατύπωση προτάσεων που θα μπορούσαν να συμβάλλουν στη βελτίωση της στρατηγικής marketing της εταιρείας και στην αύξηση των ετήσιων συνδρομών.

3. Prepare Phase – Συλλογή και Προετοιμασία Δεδομένων

Η φάση “Prepare” επικεντρώνεται στη συλλογή, οργάνωση και προετοιμασία των δεδομένων που θα χρησιμοποιηθούν για την ανάλυση. Στην παρούσα μελέτη χρησιμοποιήθηκαν τα ιστορικά δεδομένα διαδρομών της Cyclistic [1], τα οποία παρέχονται στα πλαίσια του case study του Google Data Analytics Professional Certificate. Τα δεδομένα αυτά είναι δημόσια διαθέσιμα και περιλαμβάνουν πληροφορίες σχετικά με τις διαδρομές των χρηστών του συστήματος κοινόχρηστων ποδηλάτων.

Τα datasets περιέχουν πληροφορίες όπως το μοναδικό αναγνωριστικό κάθε διαδρομής (trip_id), τον χρόνο έναρξης και λήξης της διαδρομής, τη διάρκεια της διαδρομής, τους σταθμούς εκκίνησης και τερματισμού, τον τύπο χρήστη (casual rider ή annual member), καθώς και πρόσθετα στοιχεία σχετικά με τα ποδήλατα και τις διαδρομές. Τα δεδομένα οργανώνονται σε μορφή πινάκων CSV, γεγονός που επιτρέπει την εύκολη επεξεργασία και ανάλυσή τους με εργαλεία όπως Python, pandas και SQL.

Για τις ανάγκες της ανάλυσης, τα δεδομένα λήφθηκαν και αποθηκεύτηκαν σε κατάλληλη δομή φακέλων. Παράλληλα, εξετάστηκαν ζητήματα που σχετίζονται με την ακεραιότητα, την αξιοπιστία και την ιδιωτικότητα των δεδομένων. Σύμφωνα με την περιγραφή του case study, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που διασφαλίζει την προστασία προσωπικών δεδομένων και τη συμμόρφωση με τις πολιτικές απορρήτου.

Κατά τη φάση προετοιμασίας πραγματοποιήθηκε αρχικός έλεγχος της ακεραιότητας και της ποιότητας των δεδομένων. Μέσα από την προκαταρκτική διερεύνηση εντοπίστηκαν ορισμένες ελλειπίες τιμές (missing values), καθώς και πιθανά ασυνεπή ή μη έγκυρα δεδομένα σε συγκεκριμένα πεδία. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν αναλυτικότερα στη φάση επεξεργασίας και καθαρισμού των δεδομένων (Process Phase), με στόχο τη διασφάλιση της αξιοπιστίας της ανάλυσης.

Τα ιστορικά δεδομένα διαδρομών της Cyclistic παρέχουν πολύτιμες πληροφορίες σχετικά με τη συμπεριφορά των χρηστών της υπηρεσίας κοινόχρηστων ποδηλάτων. Μέσα από δεδομένα όπως η διάρκεια διαδρομών, οι ώρες και ημέρες χρήσης, οι σταθμοί εκκίνησης και τερματισμού, καθώς και ο τύπος χρήστη, καθίσταται δυνατή η αναγνώριση διαφορών μεταξύ περιστασιακών χρηστών και ετήσιων συνδρομητών. Η ανάλυση αυτών των προτύπων χρήσης συμβάλλει στην καλύτερη κατανόηση των συνηθειών των χρηστών και υποστηρίζει τη διαμόρφωση αποτελεσματικότερων στρατηγικών marketing για την αύξηση των ετήσιων συνδρομών.

Κατά την αρχική διερεύνηση των δεδομένων εντοπίστηκαν ορισμένα ζητήματα που θα μπορούσαν να επηρεάσουν την ανάλυση. Συγκεκριμένα, παρατηρήθηκαν ελλειπίες τιμές (missing values) σε ορισμένα πεδία, καθώς και πιθανές ασυνέπειες ή μη έγκυρες εγγραφές σε δεδομένα διαδρομών. Επιπλέον, λόγω περιορισμών που σχετίζονται με την προστασία προσωπικών δεδομένων, τα datasets δεν περιλαμβάνουν προσωπικά αναγνωρίσιμες πληροφορίες χρηστών, γεγονός που περιορίζει τη δυνατότητα βαθύτερης ανάλυσης της συμπεριφοράς των πελατών. Τα ζητήματα αυτά εξετάστηκαν και αντιμετωπίστηκαν κατά τις επόμενες φάσεις καθαρισμού και επεξεργασίας των δεδομένων.

Παρατίθεται ένα απόσπασμα από το αρχείο “Divvy_Trips_2019_Q1”:

trip_id	start_time	end_time	bikeid	tripduration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	gender	birthyear
21742443	2019-01-01 0:04:37	2019-01-01 0:11	2167	390	199	Wabash Ave & C	84	Milwaukee Ave & I	Subscriber	Male	1989
21742444	2019-01-01 0:08:13	2019-01-01 0:15	4386	441	44	State St & Rand	624	Dearborn St & V	Subscriber	Female	1990
21742445	2019-01-01 0:13:23	2019-01-01 0:27	1524	829	15	Racine Ave & 18	644	Western Ave & F	Subscriber	Female	1994
21742446	2019-01-01 0:13:45	2019-01-01 0:43	252	1,783.00	123	California Ave &	176	Clark St & Elm S	Subscriber	Male	1993
21742447	2019-01-01 0:14:52	2019-01-01 0:20	1170	364	173	Mies van der Ro	35	Streeter Dr & Gr	Subscriber	Male	1994
21742448	2019-01-01 0:15:33	2019-01-01 0:19	2437	216	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Female	1983
21742449	2019-01-01 0:16:06	2019-01-01 0:19	2708	177	98	LaSalle St & Wa	49	Dearborn St & M	Subscriber	Male	1984
21742450	2019-01-01 0:18:41	2019-01-01 0:20	2796	100	211	St. Clair St & Eri	142	McClurg Ct & Er	Subscriber	Male	1990
21742451	2019-01-01 0:18:43	2019-01-01 0:47	6205	1,727.00	150	Fort Dearborn D	148	State St & 33rd S	Subscriber	Male	1995
21742452	2019-01-01 0:19:18	2019-01-01 0:24	3939	336	268	Lake Shore Dr &	141	Clark St & Lincol	Subscriber	Male	1996
21742453	2019-01-01 0:20:34	2019-01-01 0:35	6243	886	299	Halsted St & Ro	295	Broadway & Arg	Subscriber	Male	1994
21742454	2019-01-01 0:21:52	2019-01-01 0:32	6300	653	204	Prairie Ave & Ga	420	Ellis Ave & 55th	Subscriber	Female	1994
21742455	2019-01-01 0:23:04	2019-01-01 0:33	3029	601	90	Millennium Park	255	Indiana Ave & R	Subscriber	Male	1986
21742456	2019-01-01 0:23:43	2019-01-01 0:33	84	562	90	Millennium Park	255	Indiana Ave & R	Customer	Female	1990
21742457	2019-01-01 0:23:54	2019-01-01 0:39	5019	906	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742458	2019-01-01 0:24:08	2019-01-01 0:39	5526	892	289	Wells St & Conc	324	Stockton Dr & W	Subscriber	Female	1989
21742459	2019-01-01 0:24:13	2019-01-01 0:31	3373	407	152	Lincoln Ave & Di	166	Ashland Ave & V	Subscriber	Male	1967
21742460	2019-01-01 0:24:27	2019-01-01 0:47	5777	1,356.00	268	Lake Shore Dr &	319	Greenview Ave &	Customer	Female	1990
21742461	2019-01-01 0:25:28	2019-01-01 0:27	3940	102	35	Streeter Dr & Gr	35	Streeter Dr & Gr	Subscriber	Male	1985
21742463	2019-01-01 0:29:19	2019-01-01 1:08	3914	2,333.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742464	2019-01-01 0:29:21	2019-01-01 0:45	140	960	47	State St & Kinzie	111	Sedgwick St & H	Subscriber	Male	1957
21742465	2019-01-01 0:29:28	2019-01-01 1:07	3355	2,301.00	35	Streeter Dr & Gr	39	Wabash Ave & A	Customer		
21742466	2019-01-01 0:29:47	2019-01-01 0:49	5026	1,168.00	85	Michigan Ave &	329	Lake Shore Dr &	Subscriber	Male	1959

4. Process Phase – Καθαρισμός και Επεξεργασία Δεδομένων

Η φάση “Process” επικεντρώνεται στον καθαρισμό, τον μετασχηματισμό και την προετοιμασία των δεδομένων, ώστε αυτά να είναι κατάλληλα για αξιόπιστη ανάλυση. Στο πλαίσιο της παρούσας μελέτης πραγματοποιήθηκε έλεγχος των δεδομένων για πιθανά σφάλματα, ελλειπίες τιμές, ασυνέπειες και μη έγκυρες εγγραφές, με στόχο τη διασφάλιση της ποιότητας και της αξιοπιστίας της ανάλυσης.

Για την επεξεργασία των δεδομένων χρησιμοποιήθηκαν εργαλεία όπως Python, pandas και υπολογιστικά φύλλα Excel/Google Sheets, καθώς τα εργαλεία αυτά παρέχουν ευελιξία και δυνατότητες αποτελεσματικής διαχείρισης μεγάλου όγκου δεδομένων. Τα αρχικά datasets αποσυμπίεστηκαν και οργανώθηκαν σε κατάλληλη δομή φακέλων, ενώ δημιουργήθηκαν ξεχωριστά υποσύνολα αρχείων

για την αποθήκευση των πρωτογενών δεδομένων και των επεξεργασμένων εκδόσεών τους.


Στη συνέχεια πραγματοποιήθηκε μετασχηματισμός των δεδομένων μέσω της δημιουργίας νέων πεδίων που κρίθηκαν απαραίτητα για την ανάλυση. Συγκεκριμένα, δημιουργήθηκε το πεδίο `ride_length`, το οποίο υπολογίζει τη διάρκεια κάθε διαδρομής μέσω της διαφοράς μεταξύ της ώρας λήξης και της ώρας έναρξης της διαδρομής. Επιπλέον, δημιουργήθηκε το πεδίο `day_of_week`, το οποίο προσδιορίζει την ημέρα της εβδομάδας κατά την οποία πραγματοποιήθηκε κάθε διαδρομή, επιτρέποντας την ανάλυση προτύπων χρήσης ανά ημέρα.

Καταγραφή φάσης καθαρισμού και μετασχηματισμού δεδομένων

Στα πλαίσια αυτού του project χρησιμοποιούνται δύο αρχεία, τα `Divvy_Trips_2019_Q1` και `Divvy_Trips_2020_Q1`. Ξεκινάμε τον καθαρισμό δεδομένων από το `Divvy_Trips_2019_Q1`.


A) Το πρώτο πράγμα που ελέγχθηκε είναι το αν υπάρχουν διπλότυπες εγγραφές στο πεδίο `trip_id`, καθώς κάθε τιμή αυτού του πεδίου πρέπει να είναι μοναδική.

Δημιουργήσαμε μια προσωρινή στήλη `duplicate_check` στην οποία εφαρμόσαμε την φόρμουλα `COUNTIF(A:A, Ax)` όπου x ο αριθμός της εκάστοτε γραμμής. Ελέγχεται με αυτόν τον τρόπο το ενδεχόμενο κάποιο ID να εμφανίζεται πάνω από μία φορές στην στήλη `trip_id`. Δημιουργώντας ένα φίλτρο διαπιστώνουμε ότι η μόνη τιμή που υπάρχει στην στήλη `duplicate_check` είναι η τιμή 1 όπως φαίνεται και στην παρακάτω εικόνα. Συνεπώς, κάθε ID είναι μοναδικό και αποκλείεται το ενδεχόμενο διπλότυπου.



	M	N	O
	ride_length	day_of_week	uplicate_chec
9			
0			
4			
3			
4			
3			
4			
0			
5			
6			
4			
4			
6			
0			
9			
9			
7			

Β) Εξετάζουμε το ενδεχόμενο να υπάρχουν τιμές αρνητικές ή μηδενικές στο πεδίο `tripduration`. Βάζουμε φίλτρο στην στήλη να εμφανιστούν οι εγγραφές που έχουν μηδενική ή αρνητική τιμή στο πεδίο αυτό και παρατηρούμε ότι δεν εμφανίζεται καμία εγγραφή όπως φαίνεται και στην παρακάτω εικόνα. Συνεπώς είμαστε εντάξει και με το εν λόγω πεδίο.



Γ) Εξετάζουμε το ενδεχόμενο να υπάρχουν ελλιπείς τιμές (κενά) στα πεδία με την χρήση της συνάρτησης `COUNTBLANK()`. Διαπιστώθηκε ότι τα πεδία `gender` και `birthyear` έχουν 19.711 και 18.023 εγγραφές αντίστοιχα χωρίς τιμή. Αυτές οι μεταβλητές κρίθηκε ότι μπορούν να αξιοποιηθούν για την εξαγωγή δημογραφικών και marketing συμπερασμάτων σχετικά με τη συμπεριφορά των χρηστών. Για τον λόγο αυτό αποφασίστηκε η αφαίρεση των εγγραφών που περιείχαν κενές τιμές στα συγκεκριμένα πεδία, ώστε το τελικό dataset να χαρακτηρίζεται από μεγαλύτερη πληρότητα, συνέπεια και αξιοπιστία ως προς τα δημογραφικά χαρακτηριστικά των χρηστών. Η διαδικασία πραγματοποιήθηκε μέσω εφαρμογής φίλτρων στις αντίστοιχες στήλες με συνθήκη “Is empty” και στη συνέχεια διαγράφηκαν οι αντίστοιχες γραμμές από το dataset.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	trip_id	start_time	end_time	bikeid	tripduration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	gender	birthyear	ride_length	day_of_week	count_blank
2	21742443	2019-01-01 0:04:37	2019-01-01 0:11:07	2167	390	199	Wabash Ave & Grand Ave	84	Milwaukee Ave & Grand Ave	Subscriber	Male	1989	0:06:30	3	
3	21742444	2019-01-01 0:08:13	2019-01-01 0:15:34	4386	441	44	State St & Randolph St	624	Dearborn St & Van Buren St (*)	Subscriber	Female	1990	0:07:21	3	TRIP_ID
4	21742445	2019-01-01 0:13:23	2019-01-01 0:27:12	1524	829	15	Racine Ave & 18th St	644	Western Ave & Fillmore St (*)	Subscriber	Female	1994	0:13:49	3	0
5	21742446	2019-01-01 0:13:45	2019-01-01 0:43:28	252	1,783.00	123	California Ave & Milwaukee Ave	176	Clark St & Elm St	Subscriber	Male	1993	0:29:43	3	
6	21742447	2019-01-01 0:14:52	2019-01-01 0:20:56	1170	364	173	Miles van der Rohe Hwy & Chicago Ave	35	Streeker Dr & Grand Ave	Subscriber	Male	1994	0:06:04	3	START_TIME
7	21742448	2019-01-01 0:15:33	2019-01-01 0:19:09	2437	218	98	LaSalle St & Washington St	49	Dearborn St & Monroe St	Subscriber	Female	1983	0:03:36	3	0
8	21742449	2019-01-01 0:16:06	2019-01-01 0:19:03	2708	177	98	LaSalle St & Washington St	49	Dearborn St & Monroe St	Subscriber	Male	1984	0:02:57	3	
9	21742450	2019-01-01 0:18:41	2019-01-01 0:20:21	2796	100	211	St. Clair St & Erie St	142	McClurg Ct & Erie St	Subscriber	Male	1990	0:01:40	3	END_TIME
10	21742451	2019-01-01 0:18:43	2019-01-01 0:47:30	6205	1,727.00	150	Fort Dearborn Dr & 31st St	148	State St & 33rd St	Subscriber	Male	1995	0:28:47	3	0
11	21742452	2019-01-01 0:19:18	2019-01-01 0:24:54	3939	336	268	Lake Shore Dr & North Blvd	141	Clark St & Lincoln Ave	Subscriber	Male	1996	0:05:36	3	
12	21742453	2019-01-01 0:20:34	2019-01-01 0:35:20	6243	886	299	Halsted St & Roscoe St	295	Broadway & Argyle St	Subscriber	Male	1994	0:14:46	3	BIKEID
13	21742454	2019-01-01 0:21:52	2019-01-01 0:32:45	6300	653	204	Prairie Ave & Garfield Blvd	420	Ellis Ave & 55th St	Subscriber	Female	1994	0:10:53	3	0
14	21742455	2019-01-01 0:23:04	2019-01-01 0:33:05	3029	601	90	Millennium Park	255	Indiana Ave & Roosevelt Rd	Subscriber	Male	1986	0:10:01	3	
15	21742456	2019-01-01 0:23:43	2019-01-01 0:33:05	84	562	90	Millennium Park	255	Indiana Ave & Roosevelt Rd	Customer	Female	1990	0:09:22	3	TRIPDURATION
16	21742457	2019-01-01 0:23:54	2019-01-01 0:39:00	5919	995	289	Wells St & Concord Ln	324	Stockton Dr & Wrigleywood Ave	Subscriber	Female	1989	0:15:06	3	0
17	21742458	2019-01-01 0:24:08	2019-01-01 0:39:00	5526	892	289	Wells St & Concord Ln	324	Stockton Dr & Wrigleywood Ave	Subscriber	Female	1989	0:14:52	3	
18	21742459	2019-01-01 0:24:13	2019-01-01 0:31:00	3373	407	152	Lincoln Ave & Diversey Pkwy	166	Ashland Ave & Wrigleywood Ave	Subscriber	Male	1967	0:06:47	3	FROM_STATION_ID
19	21742460	2019-01-01 0:24:27	2019-01-01 0:47:03	5777	1,356.00	268	Lake Shore Dr & North Blvd	319	Greenview Ave & Diversey Pkwy	Customer	Female	1990	0:22:36	3	0
20	21742461	2019-01-01 0:25:28	2019-01-01 0:27:10	3940	102	35	Streeker Dr & Grand Ave	35	Streeker Dr & Grand Ave	Subscriber	Male	1985	0:01:42	3	
21	21742464	2019-01-01 0:29:21	2019-01-01 0:45:21	140	960	47	State St & Kinzie St	111	Sedgwick St & Huron St	Subscriber	Male	1957	0:16:00	3	0
22	21742465	2019-01-01 0:29:28	2019-01-01 1:07:49	3355	2,301.00	35	Streeker Dr & Grand Ave	39	Wabash Ave & Adams St	Customer			0:38:21	3	
23	21742466	2019-01-01 0:29:47	2019-01-01 0:49:15	5026	1,168.00	85	Michigan Ave & Oak St	329	Lake Shore Dr & Diversey Pkwy	Subscriber	Male	1959	0:19:28	3	TO_STATION_NAME
24	21742467	2019-01-01 0:30:48	2019-01-01 0:38:42	1998	474	289	Wells St & Concord Ln	313	Lakeview Ave & Fullerton Pkwy	Subscriber	Male	1994	0:07:54	3	0
25	21742468	2019-01-01 0:33:09	2019-01-01 0:50:25	2630	1,036.00	13	Wilton Ave & Diversey Pkwy	61	Wood St & Milwaukee Ave	Subscriber	Male	1991	0:17:16	3	
26	21742469	2019-01-01 0:34:35	2019-01-01 0:30:25	3722	230	520	Greenview Ave & Jarvis Ave	523	Eastlake Ter & Rogers Ave	Subscriber	Male	1961	0:03:50	3	USERTYPE
27	21742471	2019-01-01 0:36:11	2019-01-01 0:50:38	1166	747	256	Broadway & Sheridan Rd	297	Paulina St & Montrose Ave	Subscriber	Male	1965	0:12:27	3	0
28	21742472	2019-01-01 0:39:47	2019-01-01 0:50:38	1704	711	256	Broadway & Sheridan Rd	297	Paulina St & Montrose Ave	Subscriber	Male	1964	0:11:51	3	
29	21742473	2019-01-01 0:40:16	2019-01-01 0:49:29	1476	553	254	Pine Grove Ave & Irving Park Rd	465	Marine Dr & Ainslie St	Subscriber	Male	1990	0:09:13	3	GENDER
30	21742474	2019-01-01 0:41:46	2019-01-01 0:50:27	4614	521	66	Clinton St & Lake St	52	Michigan Ave & Lake St	Subscriber	Male	1994	0:08:41	3	19711
31	21742475	2019-01-01 0:45:37	2019-01-01 1:17:51	5583	1,934.00	464	Damen Ave & Foster Ave	30	Ashland Ave & Augusta Blvd	Subscriber	Male	1991	0:32:14	3	
32	21742476	2019-01-01 0:45:45	2019-01-01 0:50:00	1158	255	418	Ellis Ave & 53rd St	121	Blackstone Ave & Hyde Park Blvd	Subscriber	Male	1988	0:04:15	3	BIRTHYEAR
33	21742477	2019-01-01 0:46:19	2019-01-01 0:51:26	2314	307	144	Larrabee St & Webster Ave	313	Lakeview Ave & Fullerton Pkwy	Subscriber	Female	1961	0:05:07	3	18023
34	21742478	2019-01-01 0:47:49	2019-01-01 0:54:56	1411	427	253	Winthrop Ave & Lawrence Ave	463	Clark St & Benryup Ave	Subscriber	Male	1984	0:07:07	3	
35	21742479	2019-01-01 0:48:44	2019-01-01 0:59:39	6336	655	304	Broadway & Waveland Ave	332	Burling St (Halsted) & Diversey Pkwy (Temp)	Subscriber	Male	1988	0:10:55	3	RIIDE_LENGTH
36	21742480	2019-01-01 0:51:55	2019-01-01 0:54:49	5629	174	205	Halsted St & Archer Ave	135	Halsted St & 21st St	Subscriber	Male	1989	0:02:54	3	0
37	21742481	2019-01-01 0:55:35	2019-01-01 0:57:35	5248	120	522	Blossworth Ave & Howard Ave	520	Greenview Ave & Jarvis Ave	Subscriber	Male	1975	0:02:00	3	
38	21742483	2019-01-01 0:58:09	2019-01-01 1:15:33	5875	1,044.00	144	Larrabee St & Webster Ave	185	State St & Armitage Ave	Subscriber	Male	1989	0:17:24	3	DAY_OF_WEEK
39	21742484	2019-01-01 0:58:33	2019-01-01 1:05:17	6312	404	193	State St & 29th St	120	Wienworth Ave & Cermak Rd (Temp)	Subscriber	Male	1992	0:06:44	3	0
40	21742485	2019-01-01 0:58:44	2019-01-01 1:07:45	781	541	260	Kedzie Ave & Milwaukee Ave	507	Humboldt Blvd & Armitage Ave	Subscriber	Male	1988	0:09:01	3	
41	21742486	2019-01-01 0:58:55	2019-01-01 1:07:50	2448	535	260	Kedzie Ave & Milwaukee Ave	507	Humboldt Blvd & Armitage Ave	Subscriber	Female	1988	0:08:55	3	

Δ) Ελέγχουμε τις τιμές του πεδίου ride_length, δηλαδή την διάρκεια κάθε διαδρομής για ακραίες τιμές (outliers).

Εφαρμόζοντας φθίνουσα ταξινόμηση στις εγγραφές βάσει του εν λόγω πεδίου, διαπιστώνουμε ότι υπάρχουν πλειάδες που έχουν παράλογες για την φύση του αντικειμένου τιμές, δηλαδή κάποιες διαδρομές είναι πολύ μεγάλης διάρκειας. Λήφθηκε η απόφαση όσες εγγραφές έχουν τιμή ride_length μεγαλύτερη της μίας ώρας να διαγραφούν, καθώς θεωρούνται άκυρες. Μόλις περίπου 1.900 τέτοιες εγγραφές υπάρχουν στις προσεγγιστικά 350 χιλιάδες που έχει συνολικά το αρχείο. Πιθανότατα πρόκειται για διαδρομές τις οποίες οι χρήστες ξέχασαν να τερματίσουν.

Εφαρμόστηκε και αύξουσα ταξινόμηση για να ελέγξουμε αν υπάρχουν παράλογα μικρές τιμές στο πεδίο αυτό. Η μικρότερη διάρκεια που υπάρχει στο αρχείο είναι 1 λεπτό και 1 δευτερόλεπτο, την οποία θεωρούμε λογική.

Ε) Ελέγχουμε για ακραίες τιμές (outliers) και στις τιμές του πεδίου birthyear. Υπενθυμίζουμε ότι το αρχείο έχει εγγραφές από το έτος 2019.


Εφαρμόζουμε φθίνουσα ταξινόμηση στο εν λόγω πεδίο και παρατηρούμε ότι η πιο μεγάλη τιμή του πεδίου είναι η 2003. Η χρονολογία αυτή θεωρείται αποδεκτή, καθώς ένα άτομο 16 ετών μπορεί να νοικιάσει ποδήλατο.

Εφαρμόζουμε τώρα αύξουσα ταξινόμηση στο εν λόγω πεδίο και παρατηρούμε πληθώρα εγγραφών που έχουν τιμή παράλογη.

station	to_station_name	usertype	gender	birthyear	ride_length	day_of_week
213	Leavitt St & North Ave	Subscriber	Male	1900	0:01:15	6
66	Clinton St & Lake St	Subscriber	Male	1900	0:01:47	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:06	2
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:06	1
61	Wood St & Milwaukee Ave	Subscriber	Male	1900	0:03:15	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:21	4
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:23	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:24	4
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:32	1
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:33	4
213	Leavitt St & North Ave	Subscriber	Male	1900	0:03:38	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:03:52	6
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:04	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:10	5
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:11	7
213	Leavitt St & North Ave	Subscriber	Male	1900	0:04:14	1
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:19	1
158	Milwaukee Ave & Wabansia Ave	Subscriber	Male	1900	0:04:23	6
159	Claremont Ave & Hirsch St	Subscriber	Male	1900	0:04:25	3
130	Damen Ave & Division St	Subscriber	Male	1900	0:04:30	6
213	Leavitt St & North Ave	Subscriber	Male	1900	0:05:04	1
158	Milwaukee Ave & Wabansia Ave	Subscriber	Male	1900	0:05:52	4
509	Troy St & North Ave	Subscriber	Male	1900	0:06:26	5
334	Lake Shore Dr & Belmont Ave	Subscriber	Male	1900	0:06:57	7

Όπως φαίνεται στην παραπάνω εικόνα, υπάρχουν εγγραφές που έχουν ως ημερομηνία γέννησης το έτος 1.900. Προφανώς η τιμή αυτή είναι άκυρη. Θέτουμε ως λογικό όριο στο πεδίο αυτό την χρονολογία 1939, και σβήνουμε όλες τις εγγραφές που έχουν παλαιότερη (183 εγγραφές).

Ζ) Τέλος. κάνουμε έναν έλεγχο ότι τα πεδία usertype και gender έχουν αποδεκτές τιμές. Εφαρμόζουμε φίλτρο και ελέγχουμε τις υπάρχουσες τιμές. Διαπιστώνουμε ότι και τα δύο πεδία είναι εντάξει.



Στην συνέχεια εξετάζουμε το αρχείο Divvy_Trips_2020_Q1.

Κατά την εξέταση των datasets Divvy_Trips_2019_Q1 και Divvy_Trips_2020_Q1 διαπιστώθηκαν σημαντικές διαφορές τόσο στη δομή όσο και στο περιεχόμενο των δεδομένων. Συγκεκριμένα, το dataset του 2019 χρησιμοποιεί το πεδίο trip_id με αριθμητικές τιμές, ενώ στο dataset του 2020 το αντίστοιχο πεδίο ονομάζεται ride_id και περιλαμβάνει αλφαριθμητικές τιμές. Επιπλέον, τα πεδία start_time και end_time του 2019 αντικαθίστανται από τα started_at και ended_at στο dataset του 2020. Παρατηρείται επίσης αλλαγή στο πεδίο κατηγοριοποίησης των χρηστών, καθώς το usertype με τιμές Subscriber και Customer αντικαθίσταται από το member_casual με τιμές member και casual. Το dataset του 2019 περιλαμβάνει δημογραφικά στοιχεία όπως gender και birthyear, τα οποία απουσιάζουν πλήρως από το dataset του 2020. Αντίθετα, το dataset του 2020 περιέχει επιπλέον πληροφορίες όπως το πεδίο rideable_type και γεωγραφικές συντεταγμένες (start_lat, start_lng, end_lat, end_lng), οι οποίες δεν υπάρχουν στο dataset του 2019. Τέλος, στο dataset του 2019 η διάρκεια διαδρομής παρέχεται έτοιμη μέσω του πεδίου tripduration, ενώ στο dataset του 2020 απαιτείται υπολογισμός της διάρκειας από τα χρονικά πεδία έναρξης και λήξης της διαδρομής. Παρατίθεται απόσπασμα του αρχείου 2020 για κατανόηση του schema του:

ride_id	rideable_type	started_at	ended_at	start_station_name	start_station_id	end_station_name	end_station_id	start_lat	start_lng	end_lat	end_lng	member_casual
EACB19130B0CDA4A	docked_bike	2020-01-21 20:06:59	2020-01-21 20:14:30	Western Ave & Leland Ave	239	Clark St & Leland Ave	326	41.9665	-87.6884	41.9671	-87.6674	member
8FED874C809DC021	docked_bike	2020-01-30 14:22:39	2020-01-30 14:26:22	Clark St & Montrose Ave	234	Southport Ave & Irving Park Rd	318	41.9616	-87.666	41.9542	-87.6644	member
789F3C21E472CA96	docked_bike	2020-01-09 19:29:26	2020-01-09 19:32:17	Broadway & Belmont Ave	296	Wilton Ave & Belmont Ave	117	41.9401	-87.6455	41.9402	-87.653	member
C9A388DAC6ABF313	docked_bike	2020-01-06 16:17:07	2020-01-06 16:25:56	Clark St & Randolph St	51	Fairbanks Ct & Grand Ave	24	41.8846	-87.6319	41.8918	-87.6206	member
9438C3CBEC0CFD662	docked_bike	2020-01-30 8:37:16	2020-01-30 8:42:48	Clinton St & Lake St	66	Wells St & Hubbard St	212	41.8856	-87.6418	41.8899	-87.6343	member
6D9C8A6938165C11	docked_bike	2020-01-10 12:33:05	2020-01-10 12:37:54	Wells St & Hubbard St	212	Desplaines St & Randolph St	96	41.8899	-87.6343	41.8846	-87.6446	member
31EB9B8F406D4C82	docked_bike	2020-01-10 13:07:35	2020-01-10 13:12:24	Desplaines St & Randolph St	96	Wells St & Hubbard St	212	41.8846	-87.6446	41.8899	-87.6343	member
A2B24E3F9C9720E3	docked_bike	2020-01-10 7:24:53	2020-01-10 7:29:50	Desplaines St & Randolph St	96	Wells St & Hubbard St	212	41.8846	-87.6446	41.8899	-87.6343	member
EE3F01E1441730B7	docked_bike	2020-01-31 16:37:16	2020-01-31 16:42:11	Wells St & Hubbard St	212	Desplaines St & Randolph St	96	41.8899	-87.6343	41.8846	-87.6446	member
19DC57F7E3140131	docked_bike	2020-01-31 9:39:17	2020-01-31 9:42:40	Clark St & Lake St	38	Orleans St & Merchandise Mart Plaza	100	41.886	-87.6309	41.8882	-87.6364	member
8639202DD9D9A41	docked_bike	2020-01-07 22:46:52	2020-01-07 22:50:08	Wilton Ave & Belmont Ave	117	Clark St & Newport St	632	41.9402	-87.653	41.9445	-87.6547	member
9E74E3BB4FFAB93A	docked_bike	2020-01-08 16:02:44	2020-01-08 16:09:04	LaSalle St & Illinois St	181	Clinton St & Washington Blvd	91	41.8908	-87.6317	41.8834	-87.6412	member
3B8B2E2F29B63597	docked_bike	2020-01-08 9:33:13	2020-01-08 9:42:02	Clinton St & Washington Blvd	91	LaSalle St & Illinois St	181	41.8834	-87.6412	41.8908	-87.6317	member
0F8517F8D21287D2	docked_bike	2020-01-08 16:02:44	2020-01-08 16:09:04	LaSalle St & Illinois St	181	Clinton St & Washington Blvd	91	41.8908	-87.6317	41.8834	-87.6412	member
E45104F1ED756AF7	docked_bike	2020-01-28 20:52:50	2020-01-28 21:09:30	California Ave & Milwaukee Ave	123	Marshfield Ave & Cortland St	58	41.9227	-87.6972	41.916	-87.6689	member
15A91638FAEC2641	docked_bike	2020-01-07 17:06:14	2020-01-07 17:42:01	Franklin St & Jackson Blvd	152	Lincoln Ave & Diversey Pkwy	152	41.8777	-87.6353	41.9322	-87.6586	member
219541294624C4B7	docked_bike	2020-01-07 8:38:55	2020-01-07 9:11:40	Wilton Ave & Diversey Pkwy	13	Franklin St & Jackson Blvd	36	41.9324	-87.6527	41.8777	-87.6353	member
013862D47804B9A4	docked_bike	2020-01-06 17:16:14	2020-01-06 17:48:21	Franklin St & Jackson Blvd	36	Lincoln Ave & Diversey Pkwy	152	41.8777	-87.6353	41.9322	-87.6586	member
0067B9B4A8438651	docked_bike	2020-01-06 8:44:31	2020-01-06 9:21:28	Lincoln Ave & Diversey Pkwy	152	Franklin St & Jackson Blvd	36	41.9322	-87.6586	41.8777	-87.6353	member
A854F81611B5A5C0	docked_bike	2020-01-19 12:04:10	2020-01-19 12:10:18	Kingsbury St & Kinzie St	133	Clark St & Chicago Ave	337	41.8892	-87.6385	41.8968	-87.6309	member
3479141FF24AD595	docked_bike	2020-01-16 17:10:39	2020-01-16 17:40:40	Lake Shore Dr & Monroe St	76	Michigan Ave & Washington St	43	41.881	-87.6167	41.884	-87.6247	casual
81D44C3E2353F9BE	docked_bike	2020-01-08 15:47:42	2020-01-08 15:58:40	Canal St & Adams St	192	Michigan Ave & Washington St	43	41.8793	-87.6399	41.884	-87.6247	member
1AA18F54DC4A8636	docked_bike	2020-01-08 6:29:01	2020-01-08 6:50:02	Indiana Ave & Roosevelt Rd	255	Canal St & Adams St	192	41.8679	-87.623	41.8793	-87.6399	member
FF5F29DCB41C9F3	docked_bike	2020-01-08 7:30:59	2020-01-08 7:33:54	Broadway & Sheridan Rd	256	Sheridan Rd & Irving Park Rd	240	41.9528	-87.65	41.9542	-87.6544	member
869F3756B34163BA	docked_bike	2020-01-23 15:23:54	2020-01-23 15:37:37	Desplaines St & Jackson Blvd	107	Michigan Ave & Washington St	43	41.8783	-87.6439	41.884	-87.6247	member
00EDF290239E4843	docked_bike	2020-01-23 14:59:58	2020-01-23 15:02:49	Canal St & Adams St	192	Desplaines St & Jackson Blvd	107	41.8793	-87.6399	41.8783	-87.6439	member
CABE2F8EB7A7639C	docked_bike	2020-01-11 14:45:48	2020-01-11 14:58:46	Western Ave & Division St	305	Wood St & Hubbard St	285	41.9029	-87.6873	41.8899	-87.6715	member
7996062626A55CEF	docked_bike	2020-01-17 13:44:55	2020-01-17 13:48:33	Franklin St & Jackson Blvd	36	Wells St & Polk St	175	41.8777	-87.6353	41.8726	-87.6335	member
142E7C9831AE8D5D	docked_bike	2020-01-08 8:23:41	2020-01-08 8:36:31	Dearborn St & Erie St	110	Franklin St & Adams St (Temp)	286	41.894	-87.6293	41.8794	-87.6355	member
82061D73814586B2	docked_bike	2020-01-08 16:22:13	2020-01-08 16:30:43	Franklin St & Jackson Blvd	36	Green St & Madison St	198	41.8777	-87.6353	41.8819	-87.6488	member
85E28F767B23E62A	docked_bike	2020-01-03 11:58:12	2020-01-03 12:05:01	Burling St (Halsted) & Diversey Pkwy (Temp)	332	Clark St & Newport St	632	41.9331	-87.6478	41.9445	-87.6547	member
8E276833E7897DAF	docked_bike	2020-01-03 11:38:04	2020-01-03 11:40:36	Wilton Ave & Diversey Pkwy	13	Halsted St & Wrightwood Ave	349	41.9324	-87.6527	41.9291	-87.6491	member
46A777303CE7C883	docked_bike	2020-01-03 9:38:11	2020-01-03 9:43:52	Clark St & Newport St	632	Wilton Ave & Diversey Pkwy	13	41.9445	-87.6547	41.9324	-87.6527	member
CDAA4546AFB6F34F5	docked_bike	2020-01-05 13:54:08	2020-01-05 14:24:03	Logan Blvd & Elston Ave	258	Stockton Dr & Wrightwood Ave	324	41.9295	-87.6842	41.9313	-87.6387	casual

Κρίνεται σκόπιμη η ενοποίηση των datasets Divvy_Trips_2019_Q1 και Divvy_Trips_2020_Q1, με στόχο τη δημιουργία ενός μεγαλύτερου και περισσότερο αντιπροσωπευτικού συνόλου δεδομένων για την ανάλυση της συμπεριφοράς των χρηστών της υπηρεσίας Cyclistic. Η συνένωση των δύο αρχείων αναμένεται να προσφέρει πληρέστερη εικόνα σχετικά με τα πρότυπα χρήσης των ποδηλάτων και να οδηγήσει σε πιο αξιόπιστα στατιστικά συμπεράσματα. Ωστόσο, πριν από την ενοποίηση των δεδομένων, λόγω του ότι

υπάρχουν σημαντικές διαφοροποιήσεις στη δομή, στη μορφή και στην ονοματοδοσία ορισμένων πεδίων μεταξύ των δύο datasets, απαιτείται να γίνει διαδικασία προσαρμογής και εναρμόνισης των δεδομένων, ώστε να διασφαλιστεί η συμβατότητα και η ομοιομορφία του τελικού συνόλου δεδομένων που θα χρησιμοποιηθεί στην ανάλυση.

Για να είναι συμβατά τα δύο αυτά datasets, αλλά και για να καθαριστεί το αρχείο 2020, αποφασίστηκαν οι εξής ενέργειες:

A) Διαγραφή των πεδίων bike_id, trip_id και ride_id. Τα IDs χρησιμεύουν μόνο ως μοναδικοί αναγνωριστές και δεν προσφέρουν αναλυτική πληροφορία, ειδικά από την στιγμή που διαθέτουμε τα ονόματα των σταθμών. Επιπρόσθετα, τα IDs δεν χρησιμοποιούνται σε aggregations ή comparisons.

Στα ονόματα των σταθμών του αρχείου 2020 παρατηρήθηκε ότι υπάρχουν οι τιμές “HQ QR” και “HUBBARD ST BIKE CHECKING (LBS-WH-TEST)”. Οι εγγραφές αυτές, περίπου 10, διαγράφηκαν.

B) Διαγραφή του πεδίου rideable_type. Η μόνη τιμή του πεδίου αυτού είναι “docked_bike”. Το πεδίο αυτό δεν προσφέρει πληροφορία για την ανάλυση που θέλουμε να κάνουμε.

Γ) Διατήρηση των πεδίων started_at, ended_at και μετονομασία τους σε start_time και end_time όπως είναι στο αρχείο 2019. Επιπρόσθετα, θα προστεθούν στο 2020 τα πεδία tripduration, ride_length και day_of_week διότι είναι χρήσιμα για duration analysis, weekday analysis και usage patterns, πληροφορία η οποία είναι σημαντική για το έργο μας. Τέλος, τα start_station_name και end_station_name του αρχείου 2020 γίνονται from_station_name και to_station_name, και τα start_station_id και end_station_id μετονομάζονται σε from_station_id και to_station_id.

Παρατηρούμε ότι ορισμένες εγγραφές έχουν end_time < start_time, δηλαδή αρνητικό tripduration. Αυτές οι εγγραφές διαγράφονται. Επίσης, κατά αντιστοιχία με το αρχείο 2019 σβήνουμε ακραία μεγάλες χρονικές διάρκειες, δηλαδή όσες είναι πάνω από μία ώρα.

Στο εν λόγω αρχείο παρατηρούμε κάτι που δεν υπήρχε στο αρχείο 2019. Παρατηρούμε πολύ μικρές χρονικές διάρκειες. Υπάρχουν εγγραφές ακόμα και με μηδενική χρονική διάρκεια. Σβήνουμε όλες τις εγγραφές που έχουν χρονική διάρκεια μικρότερη του ενός λεπτού, καθώς θεωρούνται άκυρες.

Δ) Μετατροπή των τιμών member και casual του 2020 σε Subscriber και Customer.

Ε) Διαγραφή των πεδίων birthyear και gender από το dataset του 2019, καθώς τα συγκεκριμένα πεδία δεν υπάρχουν στο dataset του 2020 και επομένως δεν μπορούν να αξιοποιηθούν με συνέπεια στο ενοποιημένο σύνολο δεδομένων. Η διατήρησή τους θα δημιουργούσε ασυμβατότητα μεταξύ των δύο datasets και θα δυσχέραινε τη διαδικασία ενοποίησης και ανάλυσης. Επιπλέον, η παρούσα μελέτη επικεντρώνεται κυρίως στη συμπεριφορά χρήσης της υπηρεσίας από διαφορετικούς τύπους χρηστών και όχι στη δημογραφική ανάλυση των πελατών. Για τον λόγο αυτό κρίθηκε καταλληλότερη η αφαίρεση των συγκεκριμένων πεδίων, ώστε να διατηρηθεί κοινή και ομοιόμορφη δομή δεδομένων μεταξύ των δύο χρονικών περιόδων. Είναι προφανές ότι ήταν εντέλει περιττή η όποια επεξεργασία είχαν υποστεί τα πεδία αυτά κατά τον καθαρισμό του αρχείου 2019.

ΣΤ) Τέλος, γίνεται έλεγχος με χρήση φίλτρων για κενές ή άκυρες τιμές στα πεδία. Δεν εντοπίζεται κάποιο σφάλμα.

Παρατίθεται η τελική μορφή των δεδομένων των αρχείων 2019 και 2020:

	A	B	C	D	E	F	G	H	I	J	K	L
	start_time	end_time	trip_duration	from_station_id	from_station_name	to_station_id	to_station_name	usertype	ride_length	day_of_week		
2	2020-02-13 16:45:42	2020-02-13 16:46:42	60	159	Wabash Ave & Grand Ave	159	Wabash Ave & Grand Ave	Subscriber	0:01:00	5		
3	2020-02-23 21:45:41	2020-02-23 21:46:41	60	223	Clifton Ave & Armitage Ave	223	Clifton Ave & Armitage Ave	Subscriber	0:01:00	1		
4	2020-02-13 7:55:55	2020-02-13 7:56:55	60	192	Canal St & Adams St	192	Canal St & Adams St	Subscriber	0:01:00	5		
5	2020-02-26 17:11:55	2020-02-26 17:12:55	60	133	Kingsbury St & Kinzie St	133	Kingsbury St & Kinzie St	Subscriber	0:01:00	4		
6	2020-02-14 8:38:46	2020-02-14 8:39:46	60	91	Clinton St & Washington Blvd	91	Clinton St & Washington Blvd	Subscriber	0:01:00	6		
7	2020-02-13 7:51:05	2020-02-13 7:52:05	60	192	Canal St & Adams St	192	Canal St & Adams St	Subscriber	0:01:00	5		
8	2020-03-12 10:10:55	2020-03-12 10:11:55	60	220	Clark St & Drummond Pl	220	Clark St & Drummond Pl	Subscriber	0:01:00	5		
9	2020-01-26 1:51:36	2020-01-26 1:52:36	60	41	Federal St & Polk St	394	Clark St & 9th St (AMLJ)	Subscriber	0:01:00	1		
10	2020-01-07 15:56:04	2020-01-07 15:57:04	60	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:00	3		
11	2020-01-15 16:21:24	2020-01-15 16:22:24	60	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:00	4		
12	2020-01-08 7:57:22	2020-01-08 7:58:22	60	291	Wells St & Evergreen Ave	291	Wells St & Evergreen Ave	Subscriber	0:01:00	4		
13	2020-01-08 7:15:45	2020-01-08 7:16:45	60	91	Clinton St & Washington Blvd	77	Clinton St & Madison St	Subscriber	0:01:00	4		
14	2020-01-07 7:15:20	2020-01-07 7:16:20	60	14	Morgan St & 18th St	14	Morgan St & 18th St	Subscriber	0:01:00	3		
15	2020-01-27 8:00:10	2020-01-27 8:01:10	60	198	Green St & Madison St	198	Green St & Madison St	Subscriber	0:01:00	2		
16	2020-01-15 17:38:00	2020-01-15 17:39:00	60	164	Franklin St & Lake St	164	Franklin St & Lake St	Subscriber	0:01:00	4		
17	2020-01-06 13:15:09	2020-01-06 13:16:09	60	197	Michigan Ave & Madison St	197	Michigan Ave & Madison St	Subscriber	0:01:00	2		
18	2020-01-10 16:38:17	2020-01-10 16:39:17	60	238	Wolcott (Ravenswood) Ave & Montrose Ave	238	Wolcott (Ravenswood) Ave & Montrose Ave	Subscriber	0:01:00	6		
19	2020-02-04 7:45:59	2020-02-04 7:46:59	60	638	Clinton St & Jackson Blvd	638	Clinton St & Jackson Blvd	Subscriber	0:01:00	3		
20	2020-02-19 18:38:22	2020-02-19 18:39:22	60	91	Clinton St & Washington Blvd	174	Canal St & Madison St	Subscriber	0:01:00	4		
21	2020-02-10 17:04:22	2020-02-10 17:05:22	60	622	California Ave & Cortez St	622	California Ave & Cortez St	Subscriber	0:01:00	2		
22	2020-02-16 11:26:36	2020-02-16 11:27:36	60	225	Halsted St & Dickens Ave	225	Halsted St & Dickens Ave	Subscriber	0:01:00	1		
23	2020-03-19 12:35:03	2020-03-19 12:36:03	60	254	Pine Grove Ave & Irving Park Rd	254	Pine Grove Ave & Irving Park Rd	Subscriber	0:01:00	5		
24	2020-03-24 20:14:32	2020-03-24 20:15:32	60	340	Clark St & Drummond Pl	220	Clark St & Drummond Pl	Subscriber	0:01:00	3		
25	2020-03-05 17:15:10	2020-03-05 17:16:10	60	350	Ashland Ave & Chicago Ave	350	Ashland Ave & Chicago Ave	Subscriber	0:01:00	5		
26	2020-03-21 19:09:06	2020-03-21 19:10:06	60	112	Green St & Randolph St	198	Green St & Madison St	Subscriber	0:01:00	7		
27	2020-01-21 16:49:15	2020-01-21 16:50:15	61	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:01	3		
28	2020-01-28 16:42:58	2020-01-28 16:43:58	61	174	Canal St & Madison St	77	Clinton St & Madison St	Subscriber	0:01:01	3		
29	2020-01-03 22:46:27	2020-01-03 22:47:27	61	230	Lincoln Ave & Roscoe St	230	Lincoln Ave & Roscoe St	Subscriber	0:01:01	6		
30	2020-01-20 19:16:42	2020-02-20 19:17:43	61	159	Claremont Ave & Hirsch St	159	Claremont Ave & Hirsch St	Subscriber	0:01:01	5		
31	2020-02-04 9:10:53	2020-02-04 9:11:54	61	302	Sheffield Ave & Wrightwood Ave	67	Sheffield Ave & Fullerton Ave	Subscriber	0:01:01	3		
32	2020-02-14 15:46:45	2020-02-14 15:47:46	61	283	LaSalle St & Jackson Blvd	283	LaSalle St & Jackson Blvd	Subscriber	0:01:01	6		
33	2020-02-26 16:31:53	2020-02-26 16:32:54	61	100	Orleans St & Merchandise Mart Plaza	100	Orleans St & Merchandise Mart Plaza	Subscriber	0:01:01	4		
34	2020-03-04 16:56:29	2020-03-04 16:57:30	61	302	Sheffield Ave & Wrightwood Ave	302	Sheffield Ave & Wrightwood Ave	Subscriber	0:01:01	4		
35	2020-03-20 18:35:23	2020-03-20 18:36:24	61	48	Larrabee St & Kingsbury St	364	Larrabee St & Oak St	Subscriber	0:01:01	6		
36	2020-03-26 10:43:56	2020-03-26 10:44:57	61	226	Racine Ave & Belmont Ave	226	Racine Ave & Belmont Ave	Subscriber	0:01:01	5		
37	2020-03-08 18:12:37	2020-03-08 18:13:38	61	21	Aberdeen St & Jackson Blvd	21	Aberdeen St & Jackson Blvd	Subscriber	0:01:01	1		
38	2020-03-05 8:17:50	2020-03-05 8:18:51	61	401	Shields Ave & 28th Pl	401	Shields Ave & 28th Pl	Subscriber	0:01:01	5		
39	2020-03-12 7:15:05	2020-03-12 7:16:06	61	88	Racine Ave & Randolph St	621	Aberdeen St & Randolph St	Subscriber	0:01:01	5		
40	2020-03-07 14:31:04	2020-03-07 14:32:05	61	35	Streeter Dr & Grand Ave	35	Streeter Dr & Grand Ave	Subscriber	0:01:01	7		
41	2020-03-08 16:17:08	2020-03-08 16:18:09	61	6	Dusable Harbor	6	Dusable Harbor	Subscriber	0:01:01	1		
42	2020-03-09 8:57:17	2020-03-09 8:58:18	61	7	Field Blvd & South Water St	7	Field Blvd & South Water St	Subscriber	0:01:01	2		
43	2020-01-17 19:05:12	2020-01-17 19:06:13	61	342	Wolcott Ave & Polk St	342	Wolcott Ave & Polk St	Subscriber	0:01:01	6		

Αντιγράφουμε τα δεδομένα του 2019 στο 2020 και δημιουργείται το τελικό αρχείο “Divny_Trips_final” με 754.966 έγκυρες εγγραφές.

Βιβλιογραφία / Αναφορές

1. <https://divvy-tripdata.s3.amazonaws.com/index.html>, "Index of bucket "divvy-tripdata".